#### **Aulas 22 a 26**

- Pipelining
  - Definição exemplo prático por analogia
  - Adaptação do conceito ao caso do MIPS
  - Problemas da solução pipelined
- Construção de um datapath com pipelining
  - Divisão em fases de execução
  - Execução das instruções
- Pipelining hazards
  - Hazards estruturais: replicação de recursos
  - Hazards de controlo: stalling, previsão, delayed branch
  - Hazards de dados: stalling, forwarding
- Datapath para o MIPS com unidades simplificadas de forwarding e stalling

Bernardo Cunha, José Luís Azevedo, Arnaldo Oliveira

## Introdução

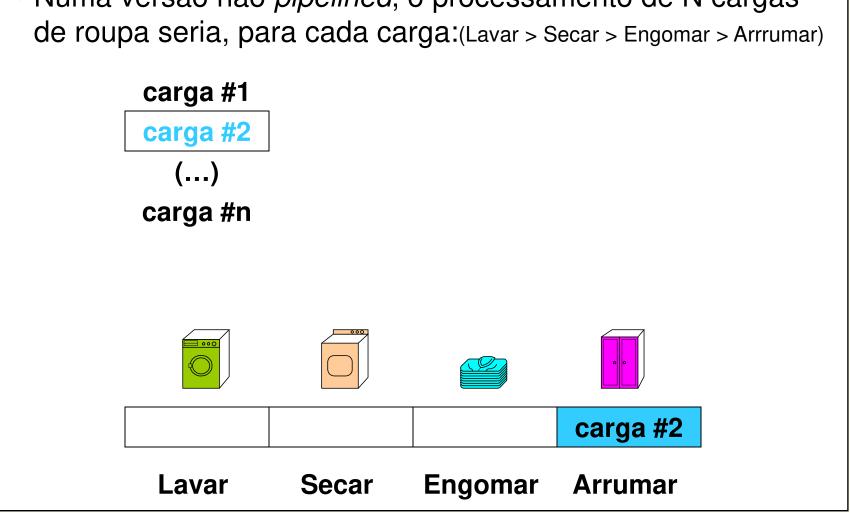
- Pipelining é uma técnica de implementação de arquiteturas do set de instruções (ISA), através da qual múltiplas instruções são executadas com algum grau de sobreposição temporal
- O objetivo é aproveitar, de forma o mais eficiente possível, os recursos disponibilizados pelo datapath, por forma a maximizar a eficiência global do processador

• O exemplo de *pipelining* que iremos observar de seguida apoia-se num conjunto de tarefas simples e intuitivas: o processo de tratamento da roupa suja ©

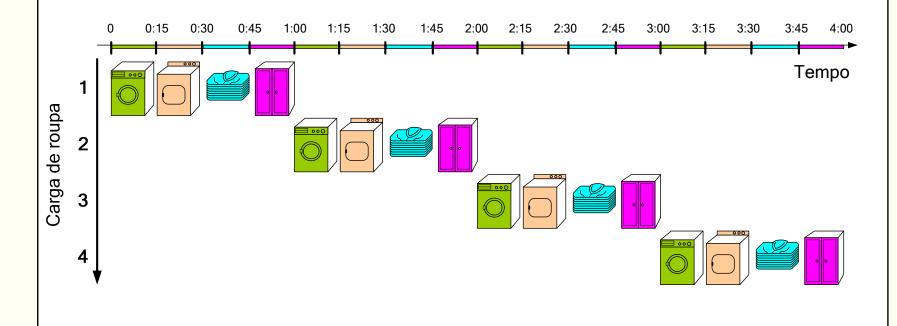


- Neste exemplo, o tratamento da roupa suja desencadeia-se nas seguintes quatro fases:
  - 1. Lavar uma carga de roupa na máquina respetiva
  - 2. Secar a roupa lavada na máquina de secar
  - 3. Passar a ferro e dobrar a roupa
  - 4. Arrumar a roupa dobrada no guarda roupa respetivo

Numa versão não pipelined, o processamento de N cargas



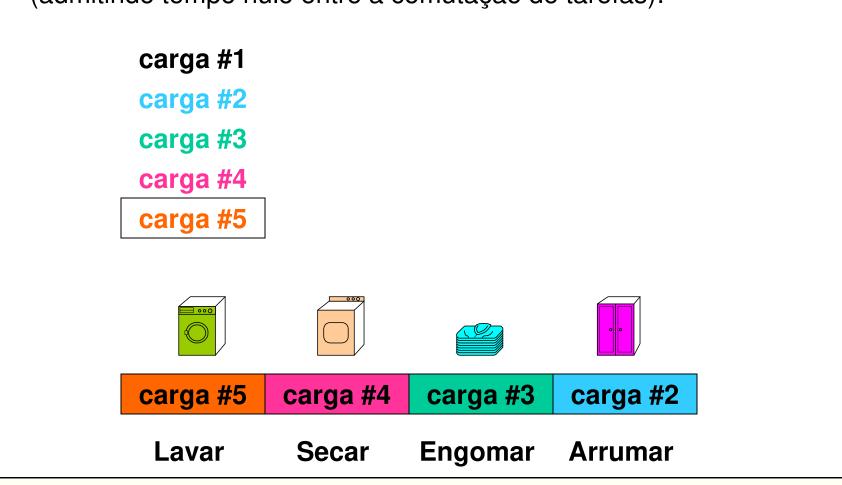
• Este processo pode então ser descrito temporalmente do seguinte modo:



Se o tempo para tratar uma carga de roupa for uma hora, tratar quatro cargas demorará **quatro horas**.

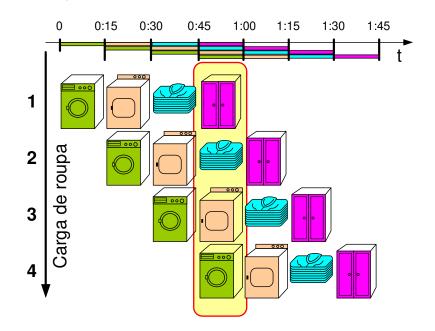
- Na versão pipelined, aproveita-se para carregar uma nova carga de roupa na máquina de lavar mal esteja concluída a lavagem da primeira carga
- O mesmo princípio se aplica a cada uma das restantes três tarefas
- Quando se inicia a arrumação da primeira carga, todos os passos (chamados estágios ou fases em pipelining) estão a funcionar em paralelo
- Maximiza-se assim a utilização dos recursos disponíveis

• Na versão *pipelined*, o processamento das cargas de roupa seria (admitindo tempo nulo entre a comutação de tarefas):



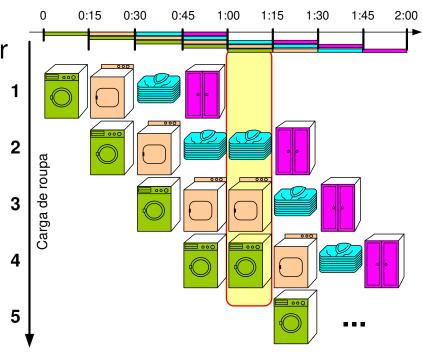
 O processo de tratamento da versão pipelined pode então ser descrito temporalmente do seguinte modo:

 Na versão pipelined, o tempo total para tratar quatro cargas será de 1h45 (ou seja 135 minutos menos (240 – 105).



 O que acontece se, por exemplo, a carga 2 n\u00e3o precisar de ser engomada?

- O que acontece se a carga 2 tiver roupa que, por alguma razão, demora mais tempo a engomar?
  - É necessária uma segunda
     "slot" de 15 min para completar a engomagem da carga 2
  - A carga 3 não pode avançar para a engomagem e permanece na máquina de secar
  - A carga 4 não pode avançar para a máquina de secar e permanece na máquina de lavar

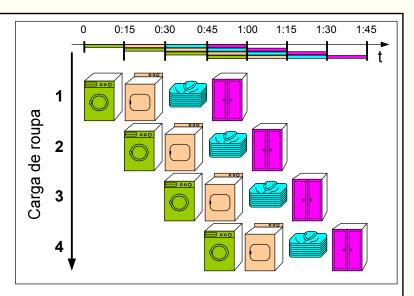


A carga 5 só é colocada na máquina de lavar no minuto 75

- O paradoxo aparente da solução pipelined é que o tempo necessário para o processamento completo de uma carga de roupa não difere do tempo da solução não pipelined
- A eficiência da solução com pipelining decorre do facto de, para um número grande de cargas de roupa, todos os passos intermédios estarem a executar em paralelo
- O resultado é o aumento do número total de cargas de roupa processadas por unidade de tempo (throughput)
- Qual o ganho de desempenho que se obtém com o sistema pipelined relativamente ao sistema normal?

## Pipelining – ganho de desempenho

 O tratamento de N cargas de roupa num sistema com F fases demorará idealmente (admitindo que cada fase demora 1 unidade de tempo):



Sistema não *pipelined*:  $T_{NON-PIPELINE} = N \times F$ 

Sistema *pipelined*:  $T_{PIPELINE} = F + (N-1) = (F-1) + N$ 

Ganho de desempenho obtido com a solução *pipelined*:

$$\frac{\text{Desempenho}_{\text{PIPELINE}}}{\text{Desempenho}_{\text{NON-PIPELINE}}} = \frac{T_{\text{NON-PIPELINE}}}{T_{\text{PIPELINE}}} = \frac{N \times F}{(F - 1) + N}$$

Se N >> (F-1), então: Ganho 
$$\approx \frac{N \times F}{N} = F$$

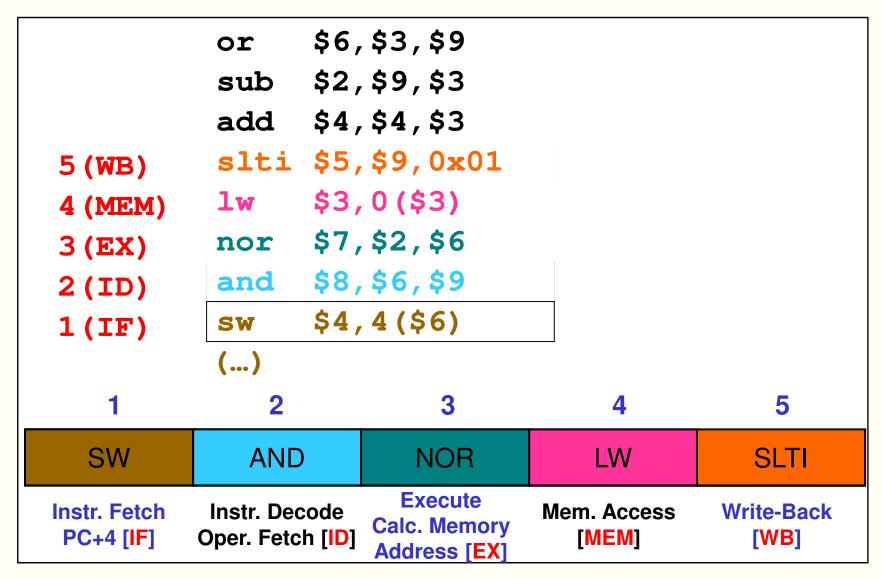
## Pipelining – ganho de desempenho

- No limite, para um número de cargas de roupa muito elevado, o ganho de desempenho (medido na forma da razão entre os tempos necessários ao tratamento da roupa, num e noutro modelo) é da ordem do número de tarefas realizadas em paralelo (isto é, igual ao número de fases do processo)
- Genericamente, poderíamos afirmar que o ganho em velocidade de execução é igual ao número de estágios do pipeline (F)
- No exemplo observado, o ganho teórico estabelece que a solução pipelined é quatro vezes mais rápida do que a solução não pipelined
- A adoção de pipelines muito longos (com muitos estágios) pode, contudo, limitar drasticamente a eficiência global

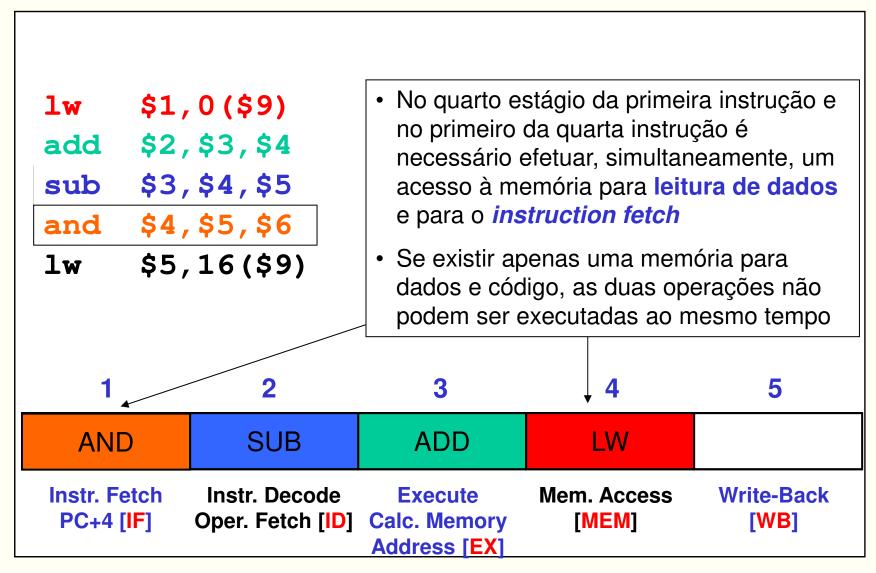
## Pipelining no MIPS

- Os mesmos princípios observados no exemplo do tratamento da roupa, podem igualmente ser aplicados aos processadores
- Para o MIPS, como já analisado, a execução da instrução mais longa (LW) pode ser dividida genericamente em cinco fases
- Parece assim razoável admitir a construção de uma solução pipelined do datapath do MIPS que implemente cinco estágios distintos, um para cada fase da execução das instruções:
  - Instruction fetch [IF] ler a instrução da memória, incremento do PC
  - 2. Operand fetch [ID] ler os registos e descodificar a instrução (os formatos das instrução do MIPS permitem que estas duas tarefas possam ser executadas em paralelo)
  - 3. Execute [EX] executar a operação ou calcular um endereço
  - 4. Memory access [MEM] aceder à memória de dados para leitura ou escrita
  - 5. Write-Back [WB] escrever o resultado no registo destino

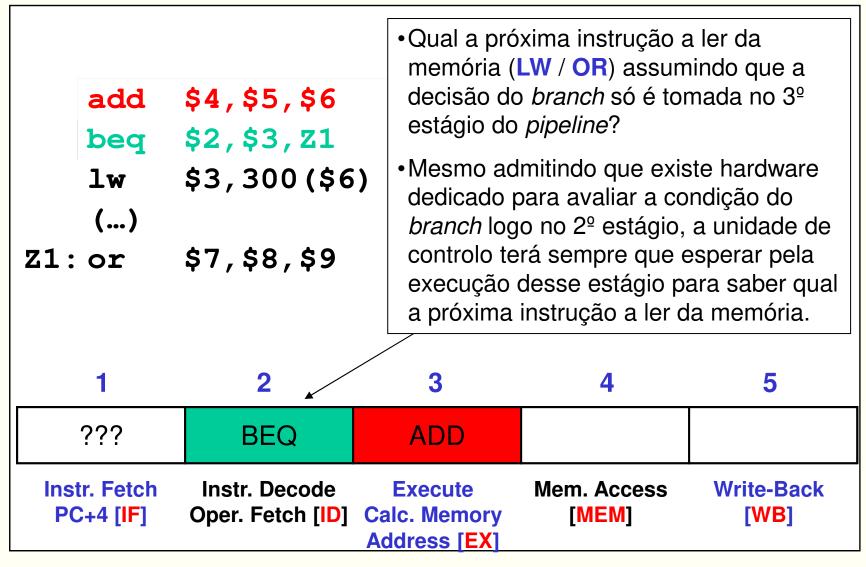
## Pipelining no MIPS



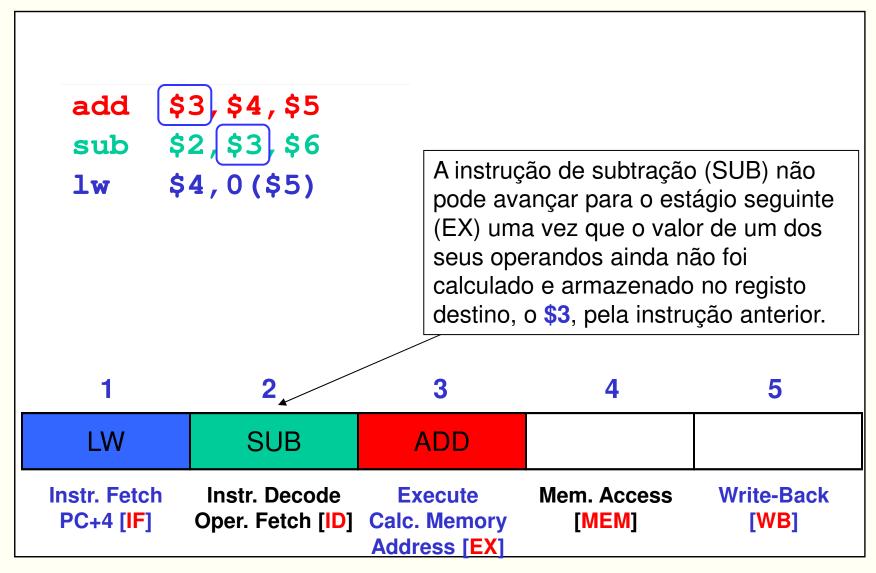
## Pipelining – Problemas (exemplo 1)



## Pipelining – Problemas (exemplo 2)



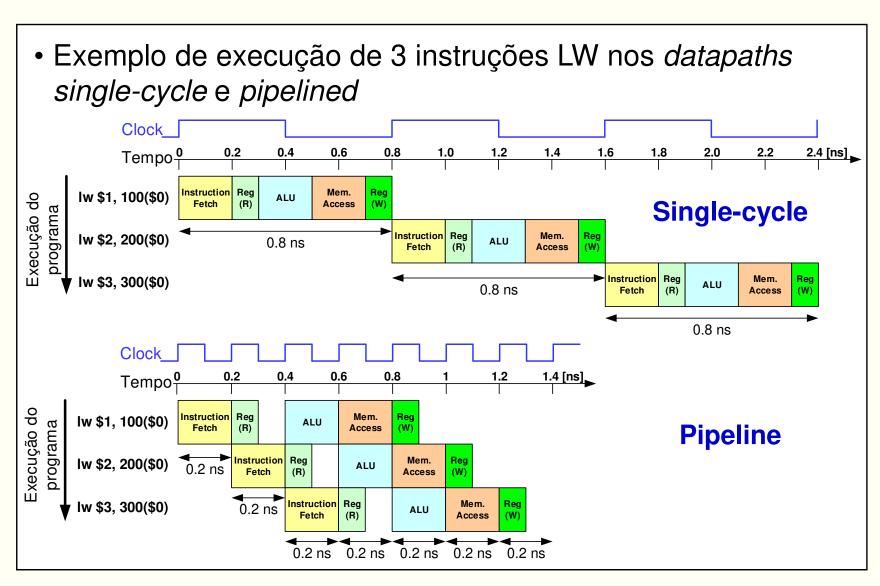
## Pipelining – Problemas (exemplo 3)



- Nos slides seguintes vamos construir e analisar um datapath pipeline que suporte a execução das instruções do MIPS que já considerámos anteriormente, isto é:
  - Acesso à memória: lw (load word) e sw (store word)
  - Tipo R: add, sub, and, or e slt
  - Imediatas: addi e slti
  - Alteração do fluxo de execução: beq e j
- Na comparação dos tempos de execução destas instruções num *DP single cycle* e num *DP pipelined*, tomamos como referência os seguintes tempos de execução de cada uma das fases:

Instruction	Instruction	Register	ALU	Memory	Register	Tempo
	Fetch	Read	Operation	Access	Write	total
Load word (lw)	200 ps	100 ps	200 ps	200 ps	100 ps	800 ps
Store word (sw)	200 ps	100 ps	200 ps	200 ps		700 ps
R-Type (add, sub, and, or, slt)	200 ps	100 ps	200 ps		100 ps	600 ps
Branch (beq)	200 ps	100 ps	200 ps			500 ps
Immediate (addi, slti)	200 ps	100 ps	200 ps		100 ps	600 ps

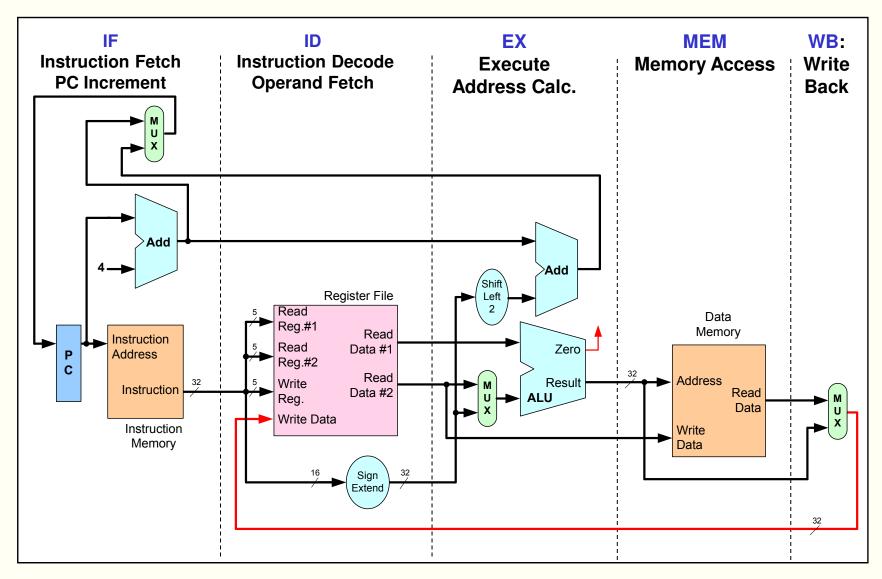
- Num datapath single cycle o período do sinal de relógio terá que ser ajustado de modo a permitir a execução da instrução mais lenta (lw)
- Na solução single cycle o período de relógio deve então ser, no mínimo, 800 ps, ou seja, todas as instruções, independentemente do tempo mínimo que poderiam durar, serão executadas num tempo de 800 ps
- Num datapath pipelined, embora alguns estágios pudessem executar em menos tempo, o período do relógio tem que ser ajustado para o atraso de propagação do elemento operativo mais lento, 200 ps no exemplo



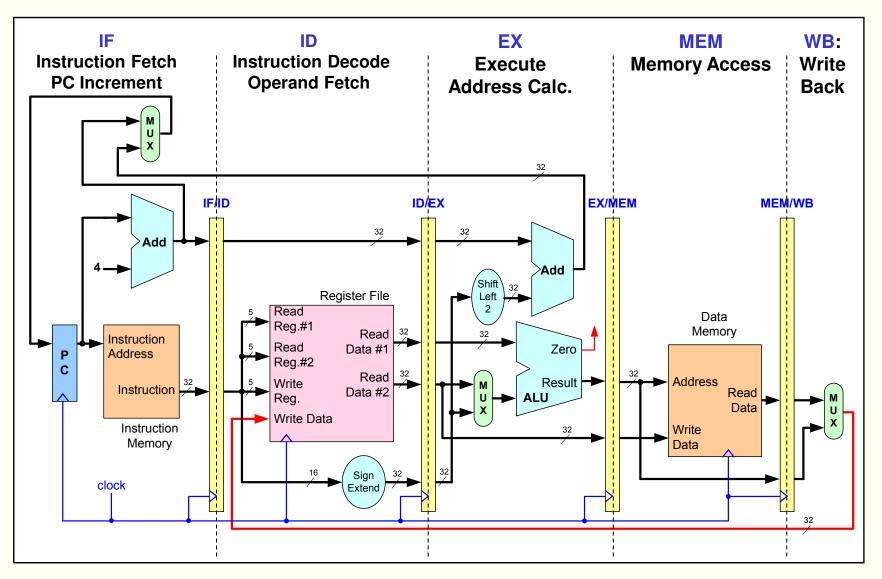
- O instruction set do MIPS (Microprocessor without Interlocked Pipeline Stages) foi concebido para uma implementação em pipeline. Os aspetos fundamentais a considerar são:
  - Instruções de comprimento fixo: Instruction Fetch e Instruction Decode podem ser feitos em estágios sucessivos (a unidade de controlo não tem que ter em consideração a dimensão da instrução descodificada)
  - Poucos formatos de instrução, com a referência aos registos a ler sempre nos mesmos campos (isso permite que os registos sejam lidos no segundo estágio ao mesmo tempo que a instrução é descodificada pela unidade de controlo)
  - Referências à memória só aparecem em instruções de load/store: o terceiro estágio pode ser usado para calcular o resultado da operação na ALU ou para calcular o endereço de memória, permitindo o acesso à memória no estágio seguinte
  - Os operandos em memória têm que estar alinhados: qualquer operação de leitura/escrita da memória pode ser feita num único estágio

- O *pipeline* implementa as cinco fases sequenciais em que são decomponíveis as instruções:
  - 1. (IF) Instruction fetch (ler a instrução da memória), incremento do PC
  - 2. (ID) Operand fetch (ler os registos) e descodificar a instrução (o formato de instrução do MIPS permite que estas duas tarefas possam ser executadas em paralelo)
  - 3. (EX) Executar a operação ou calcular um endereço
  - 4. (MEM) *Memory access* (aceder à memória de dados para leitura ou escrita)
  - 5. (WB) Write-back (escrever o resultado no registo destino)
- A solução pipelined para o MIPS parte do modelo do datapath single-cycle
- Na solução apresentada no slide seguinte não são identificados os sinais de controlo nem a respetiva unidade de controlo

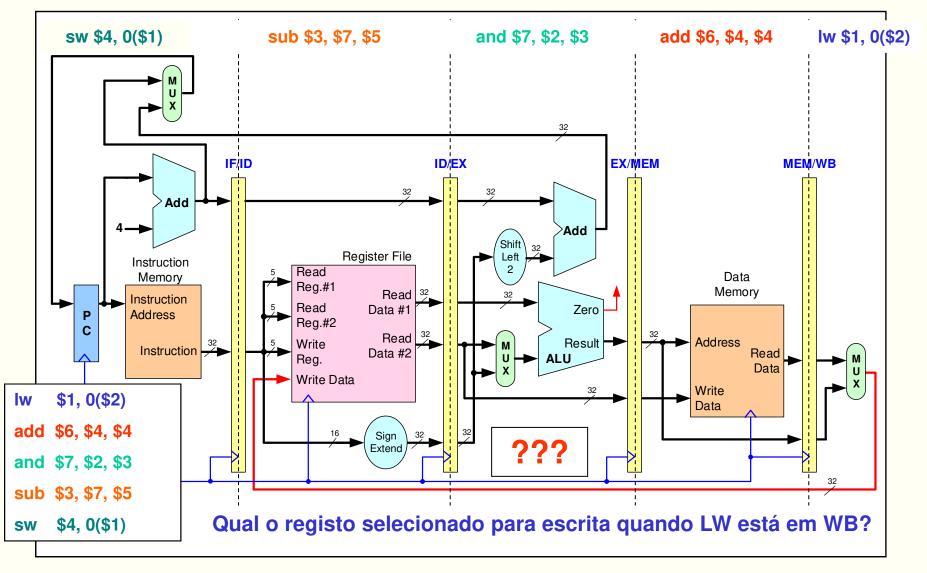
# Divisão em fases de execução



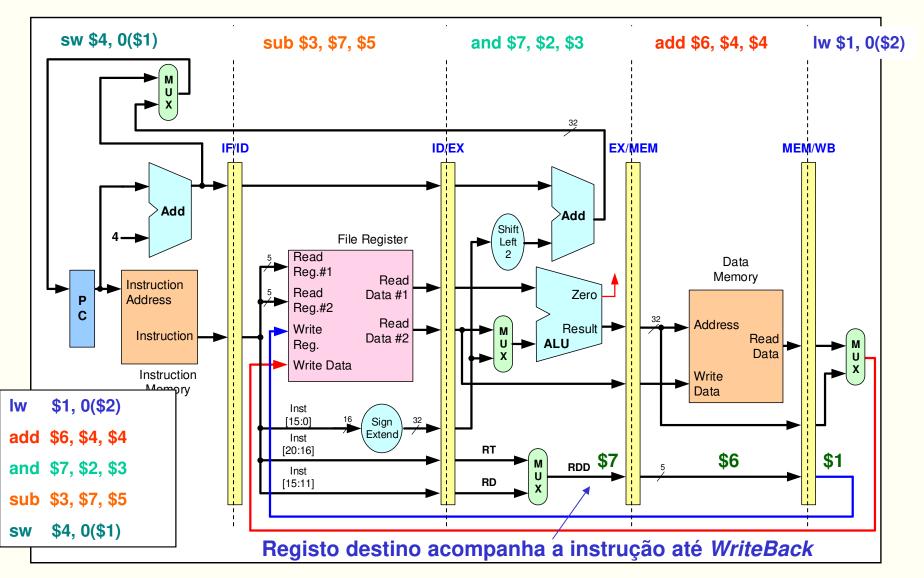
## Divisão em fases de execução – registos de pipeline



## Execução de instruções



## Datapath pipelined – 1ª versão

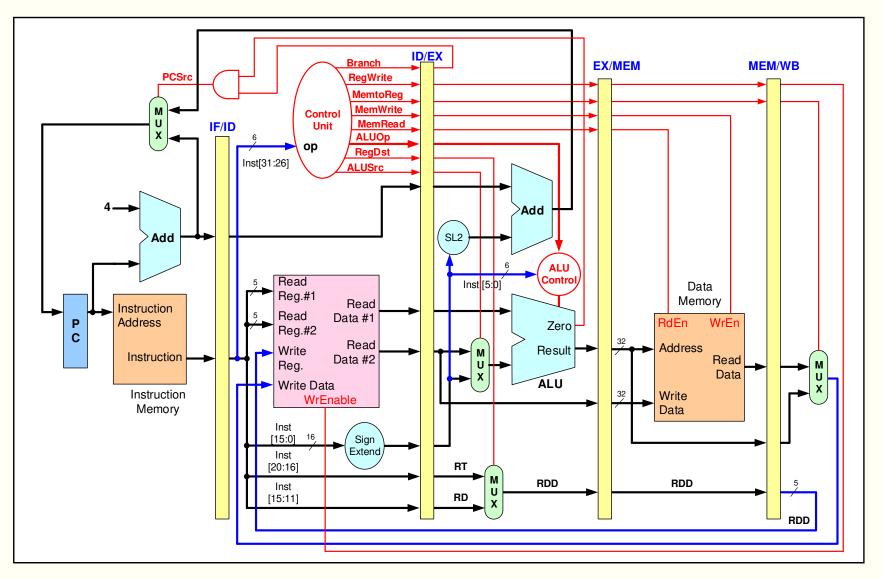


**DETI-UA** 

**Arquitetura de Computadores I** 

Aulas 22 a 26 - 26

## Datapath pipelined com unidade de controlo



#### Unidade de controlo

- A implementação pipeline do MIPS usa os mesmos sinais de controlo da versão single-cycle
- A unidade de controlo é, assim, uma unidade combinatória que gera os sinais de controlo em função do código da instrução (6 bits mais significativos da instrução, i.e., opcode) presente na fase ID
- Os sinais de controlo relevantes avançam no *pipeline* a cada ciclo de relógio (assim como os dados) estando, portanto, sincronizados com a instrução
  - Os sinais MemRead e MemWrite são propagados até à fase MEM, onde controlam o acesso à memória
  - O sinal RegWrite é propagado até WriteBack e daí controla a escrita no Register File (fase ID)
  - O sinal Branch é propagado até à fase EX (nesta versão o branch é resolvido nessa fase)

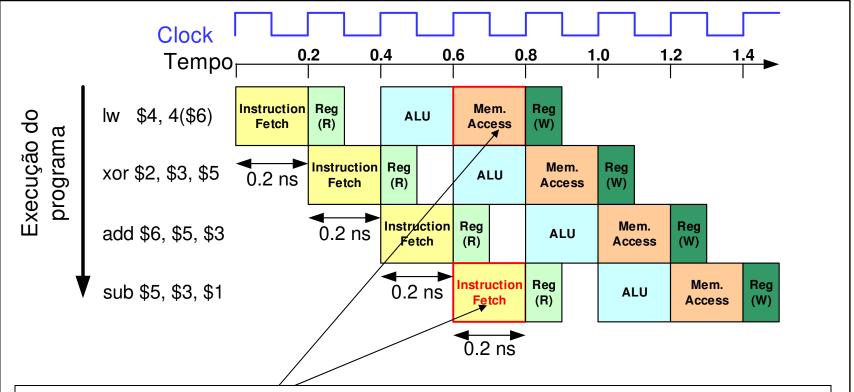
## Pipeline Hazards

- Existe um conjunto de situações particulares que podem condicionar a progressão das instruções no pipeline no próximo ciclo de relógio
- Estas situações são designadas genericamente por *hazards*,
   e podem ser agrupadas em três classes distintas:
  - Hazards estruturais
  - Hazards de controlo
  - Hazards de dados
- Nos próximos slides serão discutidas, para cada tipo de hazard, as origens e as consequências, mapeando depois esses aspetos ao nível da implementação da arquitetura pipelined do MIPS

#### Hazards Estruturais

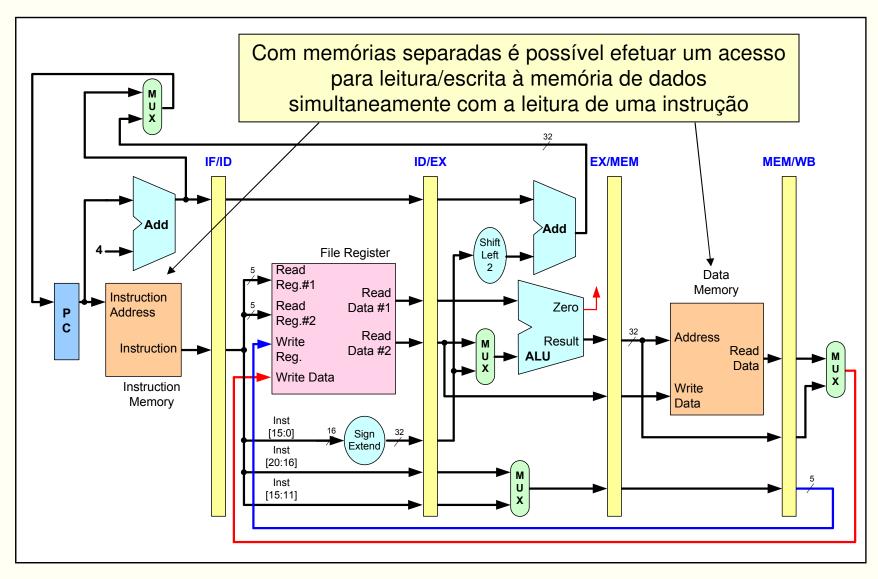
- Um *hazard* estrutural ocorre quando mais do que uma instrução necessita de aceder ao mesmo hardware
- Ocorre quando: 1) apenas existe uma memória ou 2) há instruções no pipeline com diferentes tempos de execução
- No primeiro caso o hazard estrutural é evitado duplicando a memória, i.e., uma memória de instruções e uma memória de dados (acesso em IF não conflitua com possível acesso em MEM)
- O segundo caso está fora da análise feita nestes slides; como exemplo pode pensar-se na implementação de uma instrução mais complexa que demore 2 ciclos de relógio na fase EX, usando outro elemento operativo diferente da ALU

#### Hazards Estruturais



- No quarto estágio da primeira instrução e no primeiro da quarta instrução é necessário efetuar, simultaneamente, um acesso à memória para leitura de dados e para o instruction fetch
- A não existência de memórias separadas determinaria, neste caso, a ocorrência de um *hazard* estrutural

#### Hazards Estruturais



#### Hazards de Controlo

- Um hazard de controlo ocorre quando é necessário fazer o instruction fetch de uma nova instrução e existe numa etapa mais avançada do pipeline uma instrução que pode alterar o fluxo de execução e que ainda não terminou
- Exemplo:

```
beq $5,$6,next
add $2,$3,$4
...
next: lw $3,0($4)
```

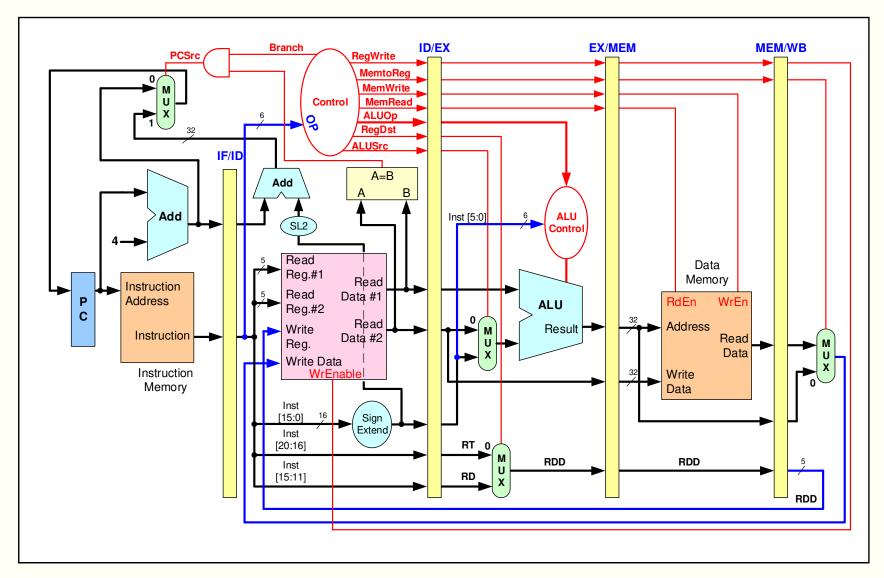
Qual a instrução que deve entrar no *pipeline* a seguir à instrução "beq"?

 No caso do MIPS, as situações de hazard de controlo surgem com as instruções de salto, (jumps e branches: j, jal, jalr, jr, beq, ...)

#### Hazards de Controlo

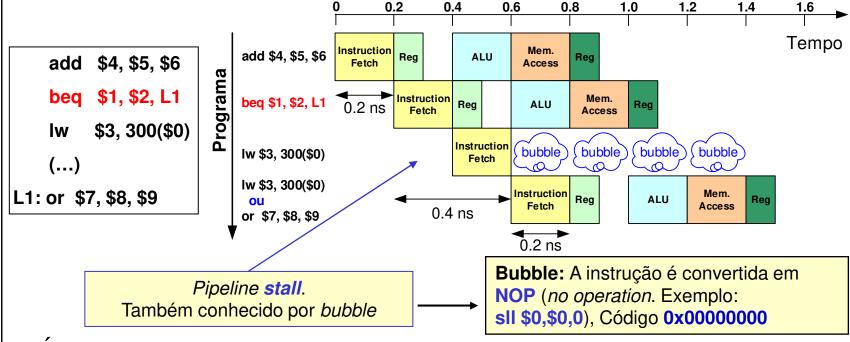
- Na versão do datapath apresentada anteriormente os branches são resolvidos em EX (3º estágio)
- Mesmo admitindo que existe hardware dedicado para avaliar a condição do branch logo no 2º estágio (ID), a unidade de controlo terá sempre que esperar pela execução desse estágio para saber qual a próxima instrução a ler da memória de instruções
- A resolução dos branches em ID minimiza o problema, e por isso a comparação dos operandos passa a ser efetuada no 2º estágio (ID), através de hardware adicional
- Do mesmo modo, o cálculo do Branch Target Address passa também a ser efetuado em ID

## Datapath com branches resolvidos em ID



#### Hazards de controlo

- Há mais do que uma solução para lidar com os hazards de controlo. A primeira que vamos analisar é designada por stalling ("parar o progresso de...")
- Nesta estratégia a unidade de controlo atrasa a entrada no pipeline da próxima instrução até saber o resultado do branch condicional



 É uma solução conservativa que tem um preço em termos de tempo de execução

#### Exercício

 Se 15% das instruções de um dado programa forem branches e jumps, qual o efeito da solução de stalling no desempenho da arquitetura, admitindo que essas instruções são resolvidas em ID?

Sem stalls: CPI = 1

Com stalls: CPI = 0.85 \* 1 + 0.15 \* 2 = 1.15

Relação de desempenho = 1 / 1,15 = 0,87

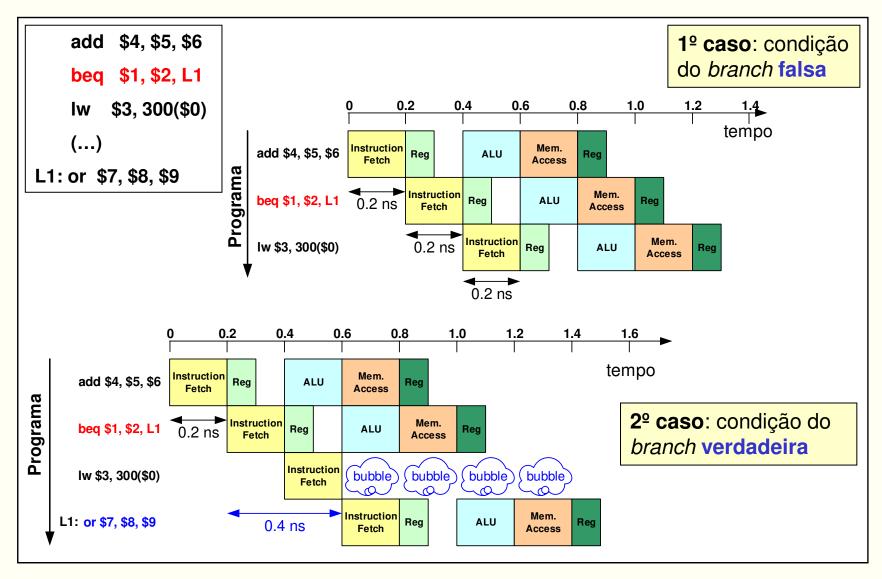
- A degradação do desempenho é tanto maior quanto mais tarde for resolvida a instrução que altera o fluxo de execução.
- Na mesma situação, se o branch / jump for resolvido em EX, a relação passa a ser:

Relação de desempenho = 1 / (0.85 \* 1 + 0.15 \* 3) = 0.77

#### Hazards de controlo

- Uma solução alternativa ao pipeline stalling é designada por previsão (prediction):
  - Prevê-se que a condição do branch é falsa (branch not taken), pelo que a próxima instrução a ser executada será a que estiver em PC+4 – estratégia designada por previsão estática not taken
  - Se a previsão falhar, a instrução entretanto lida (a seguir ao branch) é anulada (convertida em nop), continuando o instruction fetch na instrução correta
- Se a previsão estiver certa, esta estratégia permite poupar tempo
- Para o exemplo do slide anterior, se a previsão for correta 50% das vezes, a relação de desempenho passa a ser:

### Hazards de controlo – previsão estática not taken



# Hazards de controlo - previsão

- Os previsores usados nas arquiteturas atuais são mais elaborados
- Previsores estáticos: o resultado da previsão não depende do histórico da execução das instruções de branch / jump:
  - Previsor Not taken
  - Previsor Taken
  - Previsor Backward taken, Forward not taken (BTFNT)
- Previsores dinâmicos: o resultado da previsão depende da história de *branches* anteriores:
  - Guardam informação do resultado taken/not taken de branches anteriores e do target address
  - A previsão é feita com base na informação guardada

### Hazards de controlo – a solução do MIPS

- Uma outra alternativa para resolver os hazards de controlo, adotada no MIPS, é designada por delayed branch
- Nesta solução, o processador executa sempre a instrução que se segue ao branch (ou jump), independentemente de a condição ser verdadeira ou falsa
- Esta técnica é implementada com a ajuda do compilador/assembler que:
  - reorganiza as instruções do programa por forma a trocar a ordem do branch com uma instrução anterior (desde que não haja dependência entre as duas), ou
  - não sendo possível efetuar a troca de instruções introduz um
     NOP ("no operation"; ex.: sll, \$0, \$0, 0) a seguir ao branch
- Não é uma técnica comum nos processadores modernos

### Hazards de controlo – delayed branch

 Esta técnica é escondida do programador pelo compilador/assembler:

#### Código original

```
add $4, $5, $6
beq $1, $2, L1
lw $3, 300($0)
(...)
L1: or $7, $8, $9
```

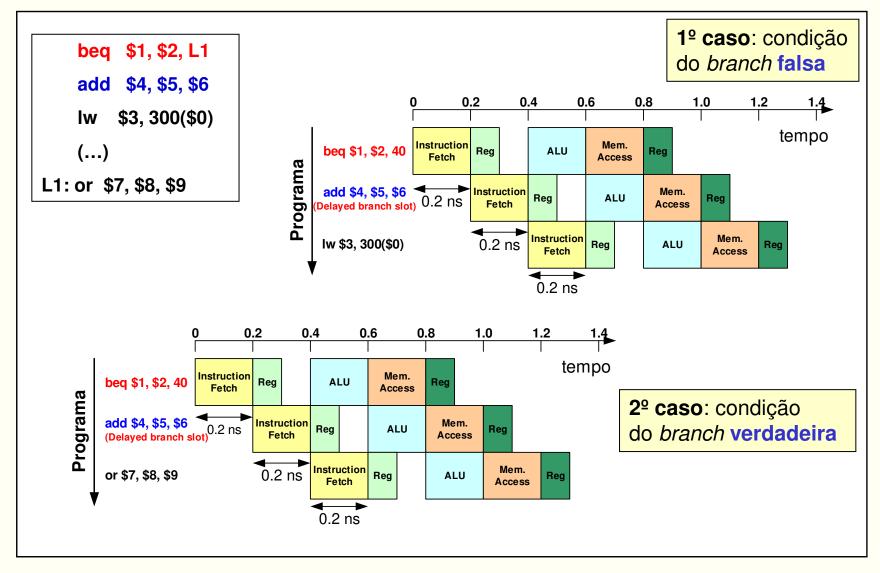
Assembler troca a ordem das duas 1<sup>a</sup>s instruções

#### Código reordenado

```
beq $1, $2, L1
add $4, $5, $6
lw $3, 300($0)
(...)
L1: or $7, $8, $9
```

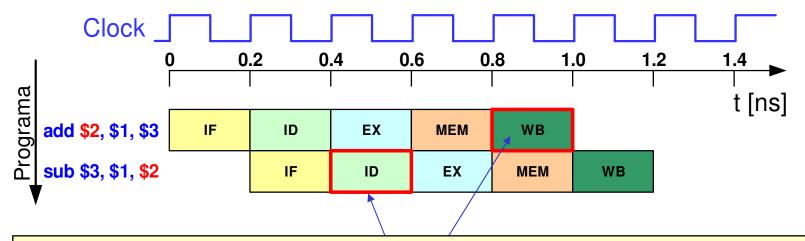
- Neste exemplo a instrução "beq" não depende do resultado produzido pela instrução "add", logo a troca das duas não altera o resultado final do programa
- No código reordenado (que é o executado no processador) a instrução "add" é sempre executada, independentemente do resultado taken/not taken do "beq"

# Hazards de controlo – delayed branch



#### Hazards de dados

- O terceiro tipo de hazards resulta da dependência existente entre o resultado calculado por uma instrução e o operando usado por outra que segue mais atrás no pipeline (i.e., mais recente)
- Exemplo: add \$2,\$1,\$3
   sub \$3,\$1,\$2



A instrução "sub \$3,\$1,\$2" não pode avançar no pipeline antes de o valor de \$2 ser calculado e armazenado pela instrução anterior (o valor é necessário em t = 0.4, mas só vai ser escrito no registo destino em t = 1)

#### Hazards de dados

- Se o resultado necessário para a instrução mais recente ainda não tiver sido armazenado, então essa instrução não poderá prosseguir porque irá tomar como operando um valor incorreto (a escrita no registo só é feita quando a instrução chega a WB)
- No exemplo anterior, a instrução SUB só poderia prosseguir para a fase EX em t=1.2
- O problema pode ser minorado, se a escrita no banco de registos for feita a meio do ciclo de relógio (i.e., na transição descendente)
  - a instrução que está na fase ID e que necessita do valor, poderá prosseguir na transição de relógio seguinte, já com o valor do registo atualizado
  - poupa-se 1 ciclo de relógio (no exemplo anterior, a instrução "sub \$3,\$1,\$2" poderá prosseguir para a fase EX em t=1.0)

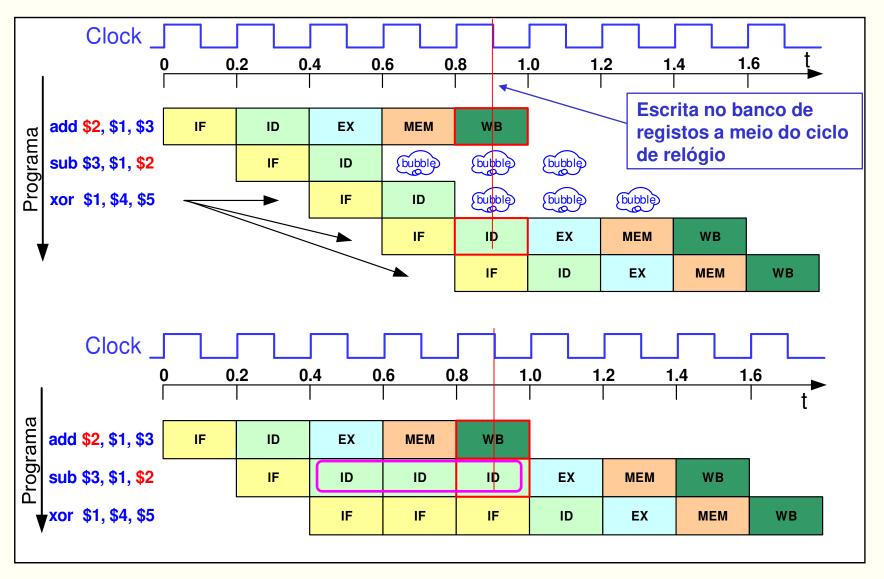
## Hazards de dados – pipeline stalling

 Para o exemplo anterior, parar a progressão da instrução SUB no estágio ID durante 2 ciclos de relógio é equivalente a introduzir dois NOP entre as duas instruções

```
add $2,$1,$3 # WB
nop # MEM
nop # EX
sub $3,$1,$2 # ID
```

- Com a escrita no banco de registos feita a meio do ciclo de relógio, a instrução SUB lê o valor atualizado de \$2, quando a instrução ADD está na fase WB
- Primeira solução stall do pipeline:
  - parar a progressão no pipeline (stall) da instrução que necessita do valor (e das anteriores), no estágio ID, até que a instrução que produz o resultado chegue ao estágio WB

# Hazards de dados – pipeline stalling



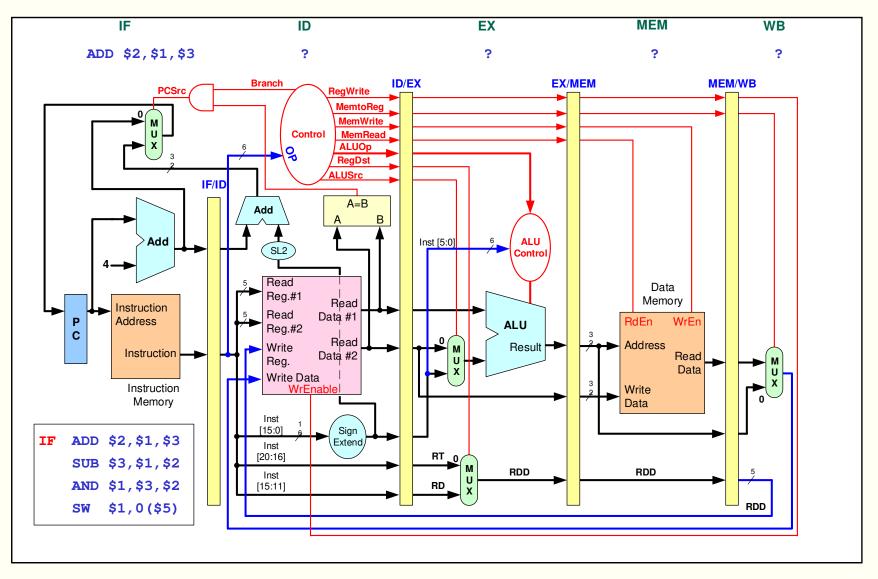
### Hazards de dados resolvidos com stalling (1)

• Exemplo:

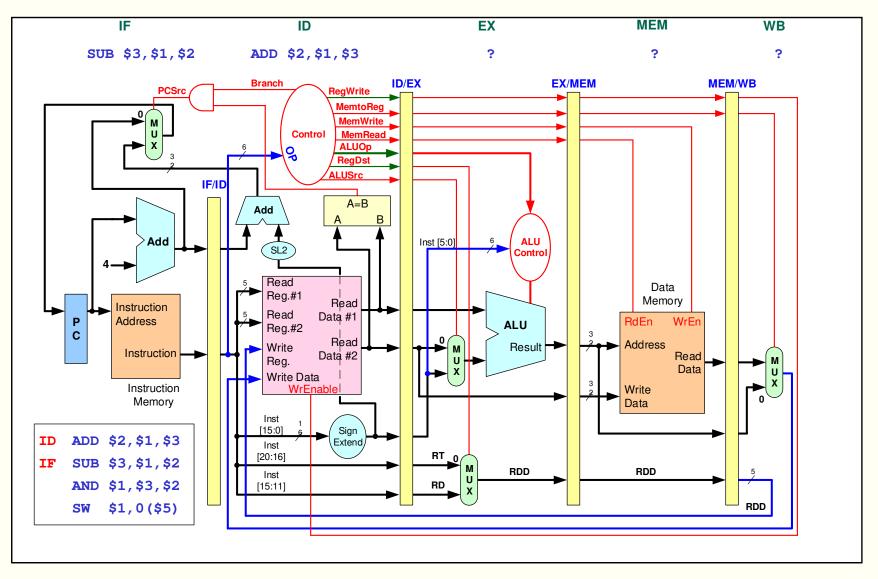
```
ADD $2,$1,$3 #
SUB $3,$1,$2 #
AND $1,$3,$2 #
SW $1,0($5) #
```

- A sequência de instruções apresenta 3 hazards de dados:
  - Na instrução SUB, resultante da dependência do registo \$2
  - Na instrução AND, resultante da dependência do registo \$3
  - Na instrução SW, resultante da dependência do registo \$1
- Cada uma destas situações de hazard de dados obriga a fazer o stall do pipeline durante 2 ciclos de relógio

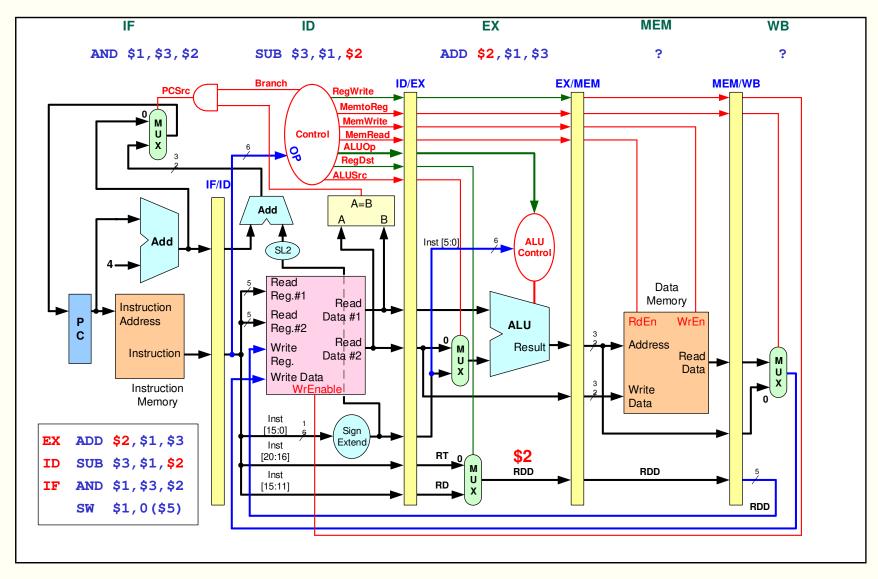
# Hazards de dados resolvidos com stalling (2)



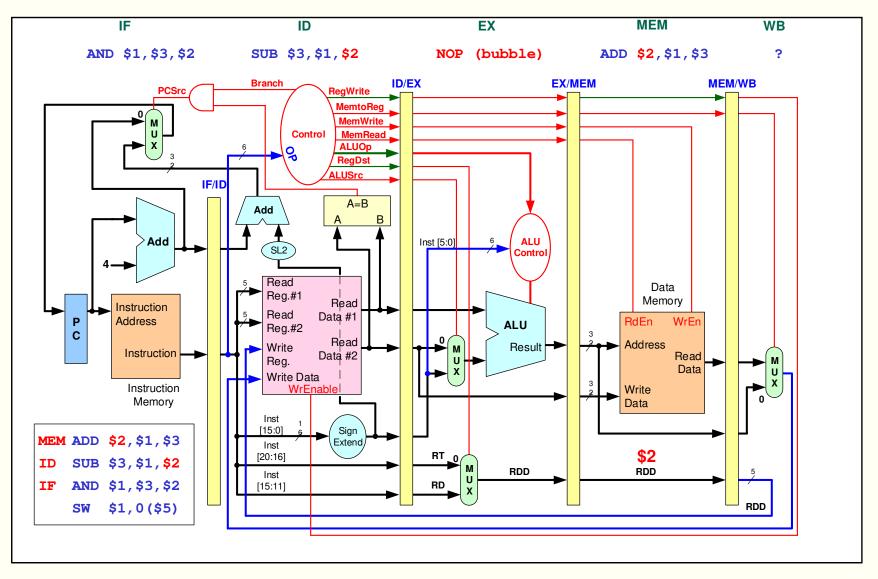
# Hazards de dados resolvidos com stalling (3)



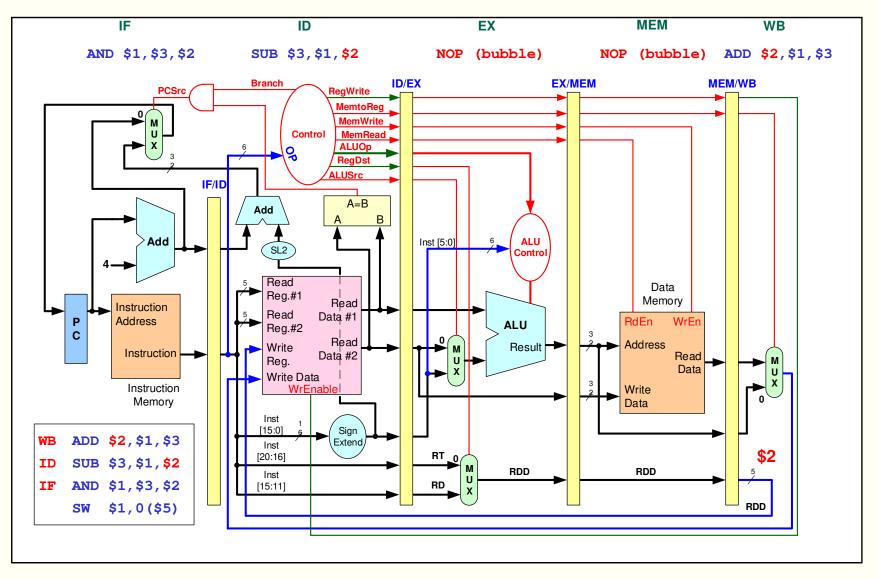
# Hazards de dados resolvidos com stalling (4)



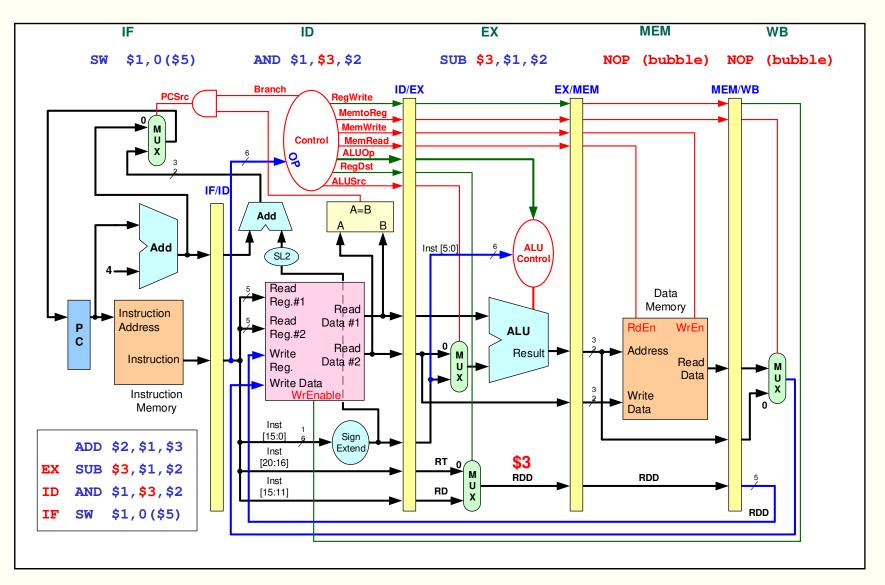
## Hazards de dados resolvidos com stalling (5)



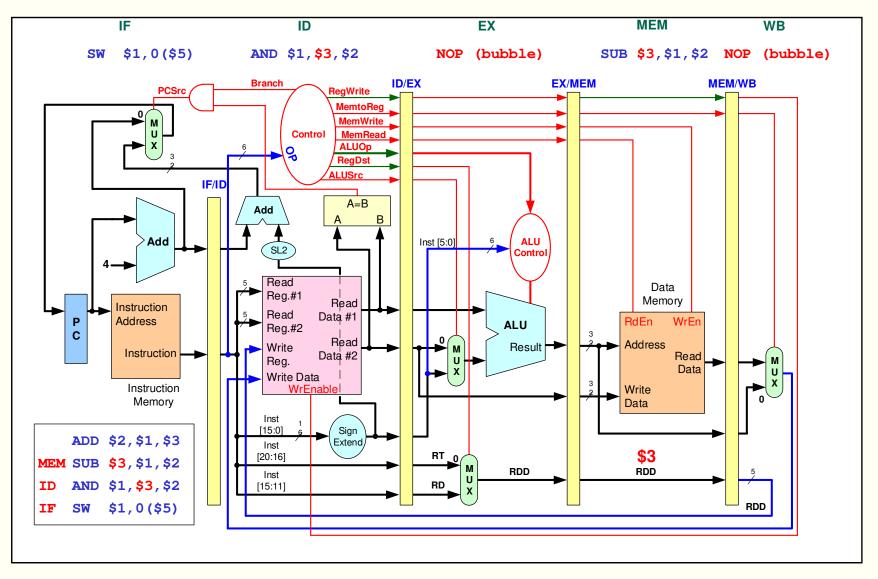
# Hazards de dados resolvidos com stalling (6)



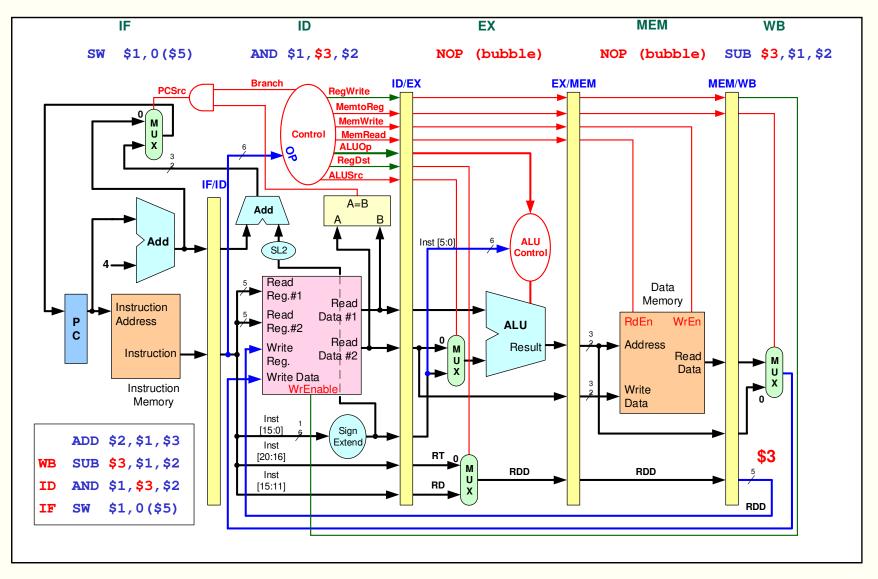
# Hazards de dados resolvidos com stalling (7)



# Hazards de dados resolvidos com stalling (8)



# Hazards de dados resolvidos com stalling (9)



#### Hazards de dados

- Esperar pela conclusão da instrução que produz o resultado (através de *stalling*) tem um impacto elevado no desempenho...
- Cada instrução com dependência atrasa a progressão do pipeline em, até, 2 ciclos de relógio (2 T); para o exemplo anterior, 6 T no total (3 hazards de dados):

Texec\_sem\_stalls = 
$$F + (N-1) = 5 + (4-1) = 8 T$$
  
Texec =  $F + (N-1) + Nr_stalls = 5 + (4-1) + 6 = 14 T$ 

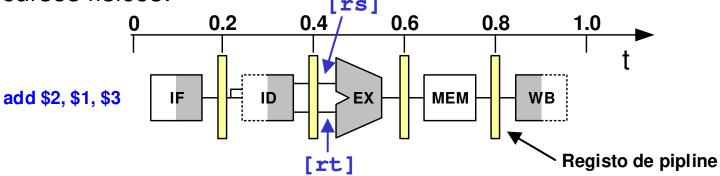
Qual será então a solução?

#### Hazards de dados

- A principal solução para a resolução de situações de hazards de dados resulta da observação de que não é necessário, na maioria dos casos, esperar pela conclusão da instrução que produz o resultado para resolver o hazard
- Por exemplo, para as instruções do tipo R, logo que a operação da instrução que vai à frente seja realizada na ALU, (Ex, 3º estágio), o resultado pode ser disponibilizado para a instrução seguinte
- Esta técnica de disponibilizar um resultado de uma instrução que ainda não terminou para uma instrução que vem a seguir na cadeia de *pipelining*, é designada por *forwarding* (ou *bypassing*)

### Representação gráfica da cadeia de pipelining

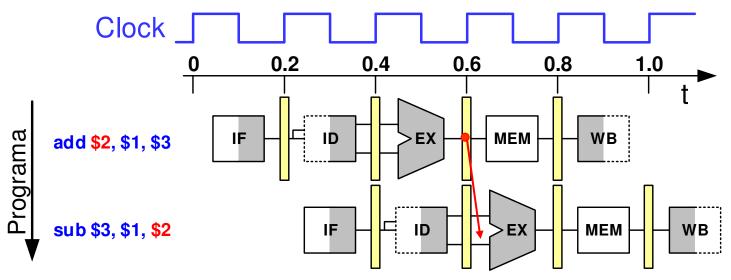
 Nesta representação gráfica usamos símbolos para representar os recursos físicos:



- IF (memória de instruções), ID (banco de registos), MEM (memória de dados), WB (banco de registos)
- Metade cinzenta à direita indica uma operação de leitura do elemento de estado
- Metade cinzenta à esquerda indica uma operação de escrita no elemento de estado
- Um quadrado branco indica que o elemento de estado não está envolvido na execução da instrução

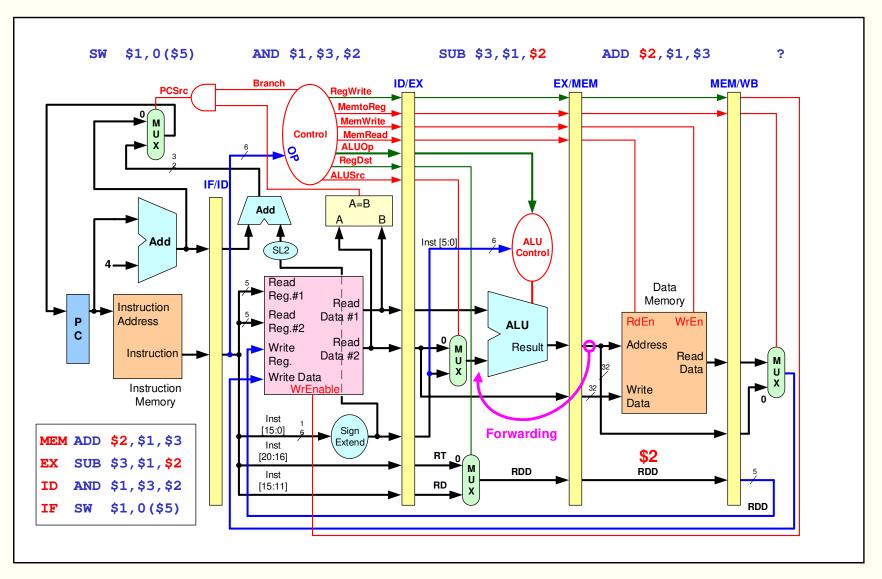
#### Hazards de dados

 Um exemplo anterior, em que se observou a existência de um hazard de dados, pode então ser representado graficamente por:



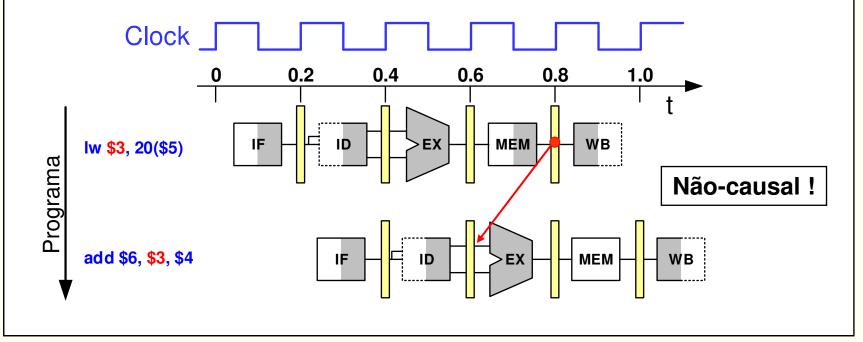
- O forwarding do valor presente no registo EX/MEM (resultado da instrução ADD) para a segunda entrada da ALU (estágio EX, instrução SUB) resolve o hazard de dados
  - Designamos esta operação por "forwarding de EX/MEM para EX" (para a segunda entrada da ALU)

# Hazards de dados - forwarding



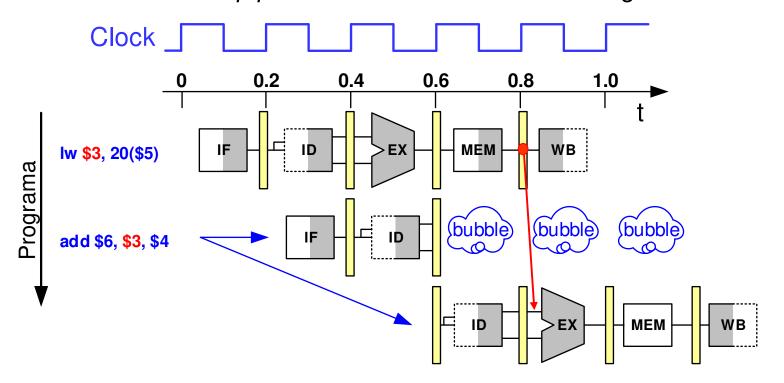
#### Hazards de dados

- Há situações em que o forwarding, por si só, não resolve o hazard de dados
- Um exemplo é o que ocorre quando uma instrução aritmética/lógica depende do resultado de uma instrução de acesso à memória (LW) que ainda não terminou



### Hazards de dados – stalling

- Para resolver a situação do slide anterior, é necessário:
  - 1. Fazer o *stall* do *pipeline* durante um ciclo de relógio



2. Fazer o *forwarding* do registo **MEM/WB** para o estágio **EX**, para a primeira entrada da ALU

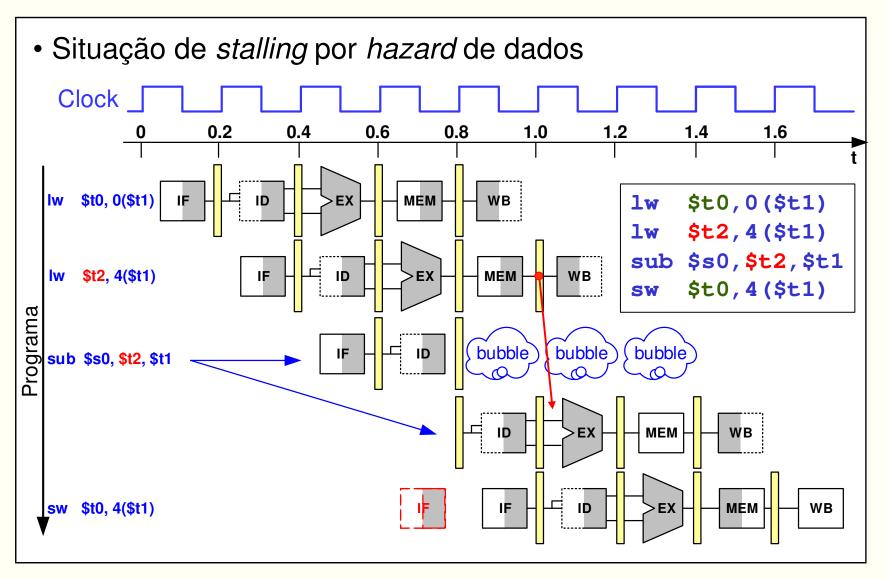
### Hazards de dados – reordenação de instruções

- Algumas situações de hazards de dados podem ser atenuadas ou resolvidas pelo compilador/assembler, através da reordenação de instruções
- A reordenação não pode comprometer o resultado final
- Código original (exemplo):

```
lw $t0,0($t1)
lw $t2,4($t1)
sub $s0,$t2,$t1 # Stalling por hazard de dados (1T)
sw $t0,4($t1)
```

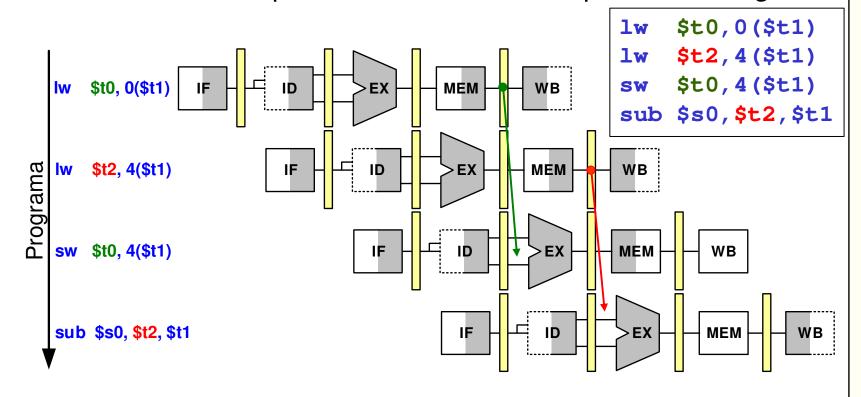
• Código reordenado pelo compilador/assembler:

# Hazards de dados – exemplo que gera stalling



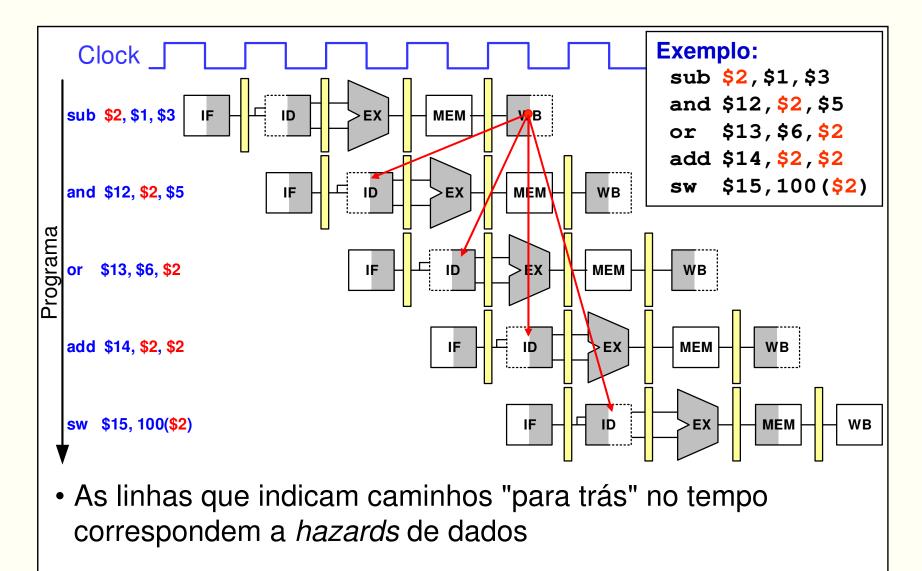
#### Hazards de dados

 A situação de stalling foi evitada pelo compilador/assembler através de reordenação. A reordenação gera um segundo hazard de dados que também é resolvido por forwarding

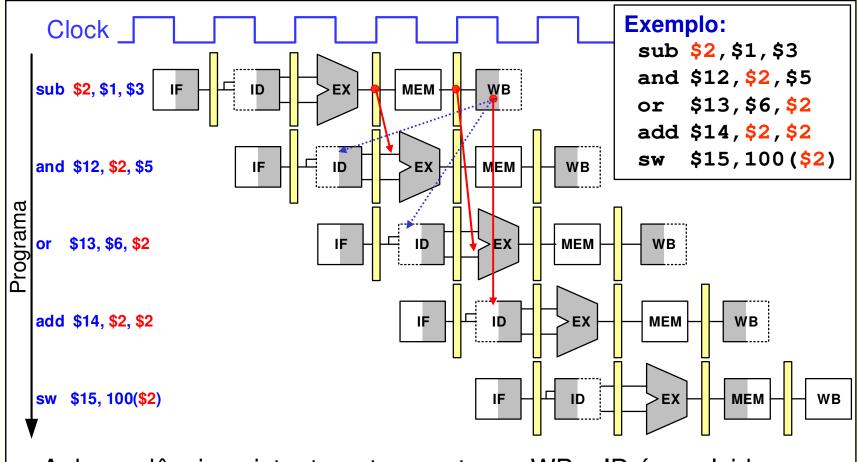


• A sequência reordenada executa em menos 1 ciclo de relógio

#### Hazards de dados – exemplo



### Hazards de dados – exemplo



 A dependência existente entre as etapas WB e ID é resolvida fazendo a escrita do Register File a meio do ciclo de relógio, permitindo que a leitura seja realizada na 2ª metade do ciclo

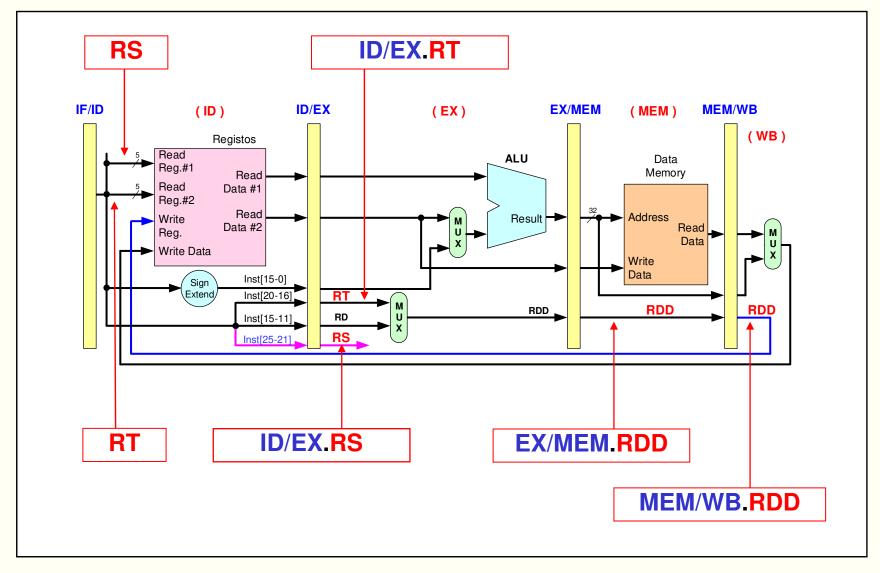
### Hazards de dados – implementação do forwarding

- Para resolver um hazard de dados através de forwarding é necessário:
  - Detetar a situação de hazard
  - Encaminhar o valor que se encontra num estágio mais avançado do pipeline para onde ele é necessário
- A resolução de uma parte significativa dos hazards de dados é feita através do encaminhando de valores para o estágio
   EX:
  - forwarding de EX/MEM para EX e de MEM/WB para EX
- As instruções de branch necessitam dos valores corretos dos registos no estágio ID
  - forwarding de EX/MEM para ID

#### Hazards de dados – encaminhamento

• Forwarding de EX/MEM para EX e de MEM/WB para EX IF/ID ID/EX **EX/MEM** MEM/WB Registos Read RS 5 Data Reg.#1 Memory Read Read Data #1 Zero Reg.#2 Read Address Result Write Read Data #2 Reg. Data Write Data Write Data Inst[15-0] Inst[20-16] RT М **RDD** RDD RDD RD Inst[15-11] Forwarding de MEM/WB **Forwarding de EX/MEM** 

# Hazards de dados - deteção



### Hazards de dados – deteção

- As situações de hazard de dados, em que há necessidade de encaminhar valores para o estágio EX são:
  - Instrução na fase MEM cujo registo destino é um registo operando de uma instrução que se encontra na fase EX; de forma simplificada:

```
EX/MEM.RDD == ID/EX.RS, e/ou
EX/MEM.RDD == ID/EX.RT
```

M add \$1,\$2,\$3EX sub \$4,\$1,\$5

 Instrução na fase WB cujo registo destino é um registo operando de uma instrução que se encontra na fase Ex; de forma simplificada:

```
MEM/WB.RDD == ID/EX.RS, e/ou
MEM/WB.RDD == ID/EX.RT
```

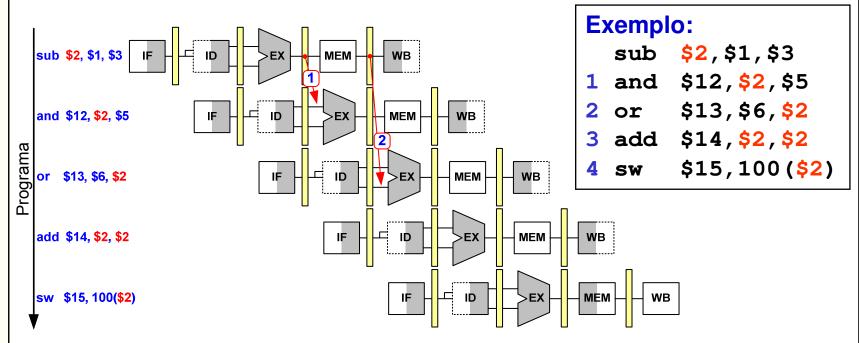
WB add \$1,\$2,\$3

M add \$6,\$2,\$3

EX sub \$4,\$5,\$1

## Hazards de dados – deteção

- A situação 3 é resolvida sem forwarding (não se considera hazard)
- A situação 4 não corresponde a um hazard de dados



- As situações de *hazard* de dados 1 e 2 podem ser detetadas por:
  - 1. EX/MEM.RDD == ID/EX.RS (EX/MEM.RDD = \$2, ID/EX.RS = \$2)
  - 2. MEM/WB.RDD == ID/EX.RT (MEM/WB.RDD = \$2, ID/EX.RT = \$2)

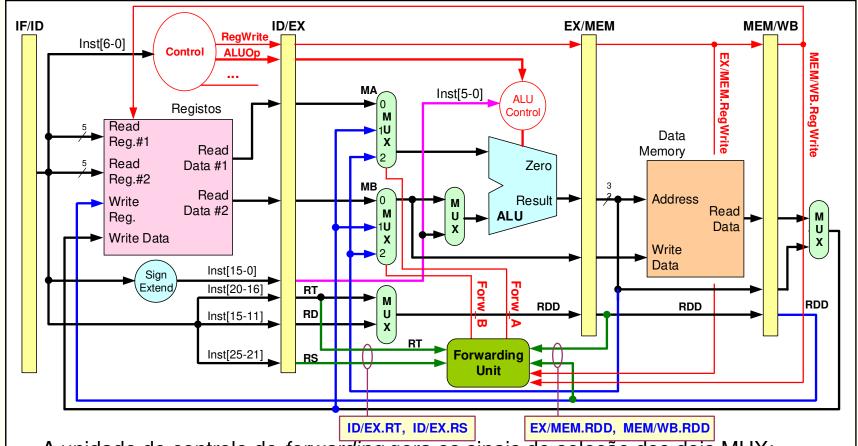
• Unidade de controlo de *forwarding*, simplificada IF/ID ID/EX EX/MEM MEM/WB RegWrite Inst[6-0] **ALUOp** Inst[5-0] Registos Control Read Data Reg.#1 Memory Read Read Data #1 Zero Reg.#2 MB Read Address Result Write Read Data #2 Reg. Data Write Data Write Data Inst[15-0] Inst[20-16] RT, RDD RDD RDD RD Inst[15-11] **Forwarding** Inst[25-21] ID/EX.RT, ID/EX.RS EX/MEM.RDD, MEM/WB.RDD

- A simples comparação dos registos não é suficiente para a correta deteção das situações de hazard de dados
- O sinal de controlo que permite a escrita no banco de registos (RegWrite) tem igualmente que ser avaliado:
  - Instrução na fase MEM que escreve o resultado num registo (RegWrite='1') igual ao registo operando de uma instrução que se encontra na fase EX:

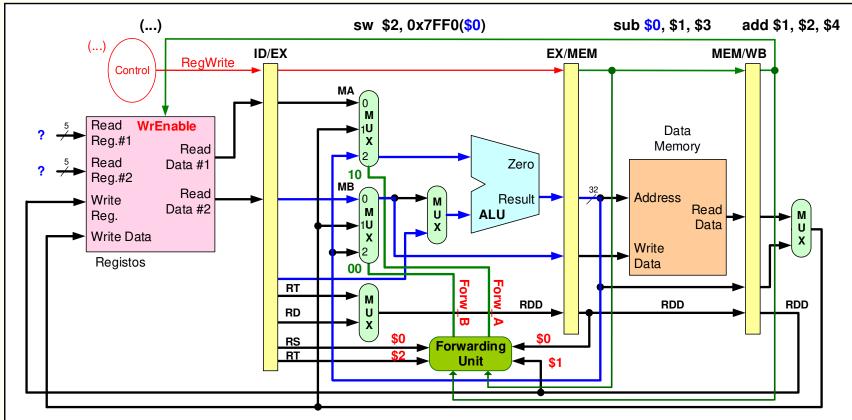
```
(EX/MEM.RegWrite == 1) and (EX/MEM.RDD == ID/EX.RS)
e/ou
(EX/MEM.RegWrite == 1) and (EX/MEM.RDD == ID/EX.RT)
```

 Instrução na fase WB que escreve o resultado num registo (RegWrite='1') igual ao registo operando de uma instrução que se encontra na fase EX:

```
(MEM/WB.RegWrite == 1) and (MEM/WB.RDD == ID/EX.RS)
e/ou
(MEM/WB.RegWrite == 1) and (MEM/WB.RDD == ID/EX.RT)
```



- A unidade de controlo de forwarding gera os sinais de seleção dos dois MUX:
  - 00 encaminhar valor lido do banco de registos
  - 01 − encaminhar o valor proveniente do registo MEM/WB (de uma instrução em WB)
  - 10 encaminhar o valor proveniente do registo **EX/MEM** (de uma instrução em MEM)



- O que acontece caso o hazard de dados resulte de um valor de EX/MEM.RDD = \$0 ou MEM/WB.RDD = \$0?
- Como resolver o problema?

## Unidade de controlo de *forwarding* (para EX) – VHDL

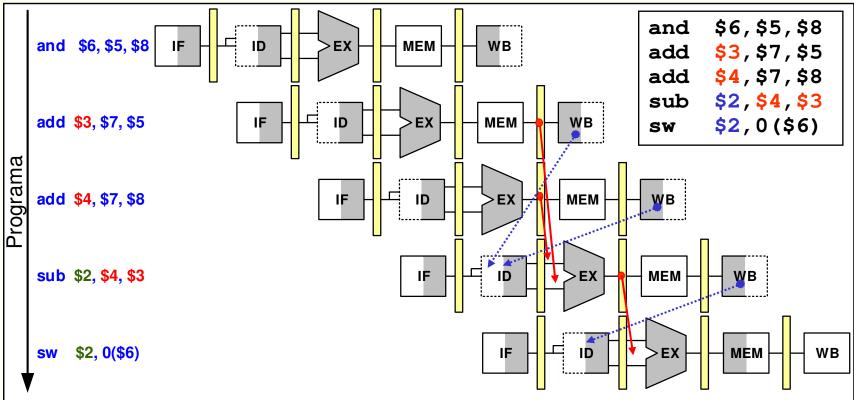
```
library ieee;
use ieee.std_logic_1164.all;
entity ForwardingUnit is
  port(ExMem_RegWrite : in std_logic;
       MemWb_RegWrite : in std_logic;
       IdEx_RS : in std_logic_vector(4 downto 0);
       IdEx_RT : in std_logic_vector(4 downto 0);
       ExMem_RDD : in std_logic_vector(4 downto 0);
       MemWb_RDD : in std_logic_vector(4 downto 0);
       Forw_A : out std_logic_vector(1 downto 0);
       Forw_B : out std_logic_vector(1 downto 0));
end ForwardingUnit;
```

### Unidade de controlo de *forwarding* (para EX) – VHDL r

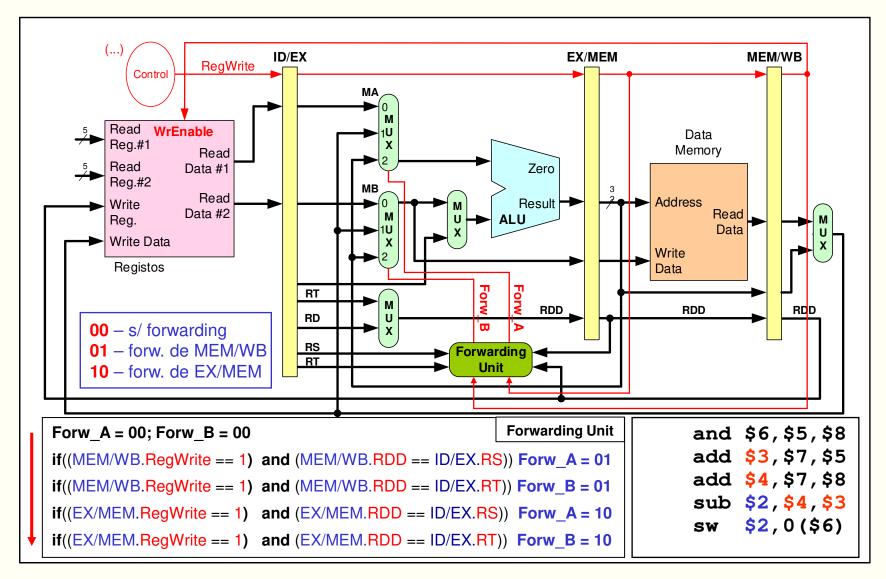
```
architecture Behavioral of ForwardingUnit is
begin
                                           1 add $2,$3,$5
  process (all)
                                           2 add $2,$2,$6
  begin
                                           3 sub $4,$2,$7
   Forw_A <= "00"; -- no hazard
   Forw_B <= "00"; -- no hazard
   if (MemWb_RegWrite = '1' and MemWb_RDD /= "00000")then
      if (MemWb_RDD = IdEx_RS) then Forw_A <= "01"; end if;</pre>
      if (MemWb_RDD = IdEx_RT) then Forw_B <= "01"; end if;</pre>
   end if;
   if (ExMem_RegWrite = '1' and ExMem_RDD /= "00000")then
      if (ExMem_RDD = IdEx_RS) then Forw_A <= "10"; end if;</pre>
      if (ExMem_RDD = IdEx_RT) then Forw_B <= "10"; end if;</pre>
   end if;
  end process;
                       00 – encaminhar valor lido do banco de registos
end Behavioral;
                       01 – encaminhar o valor proveniente do registo MEM/WB
                       10 - encaminhar o valor proveniente do registo EX/MEM
```

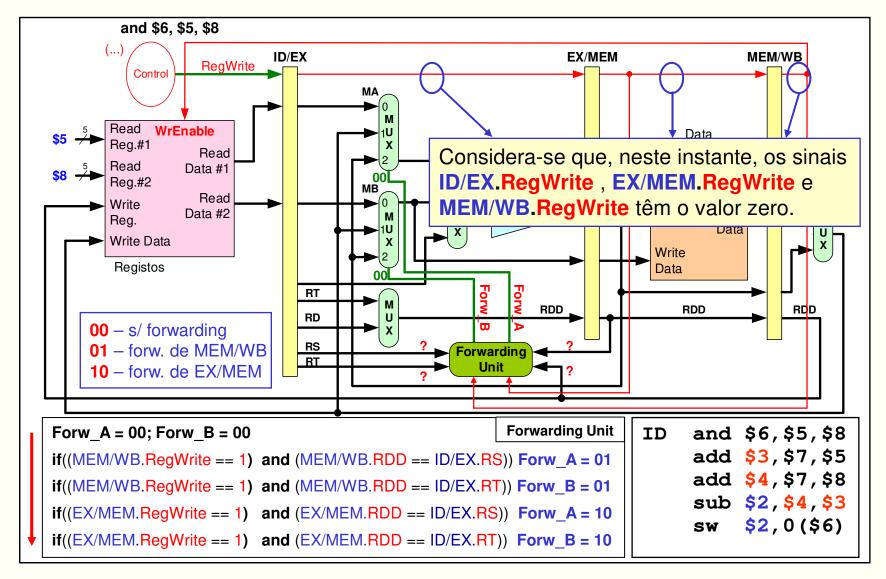
```
and $6,$5,$8
add $3,$7,$5
add $4,$7,$8
sub $2,$4,$3  # Hazard de dados: $3,$4
sw $2,0($6)  # Hazard de dados: $2
```

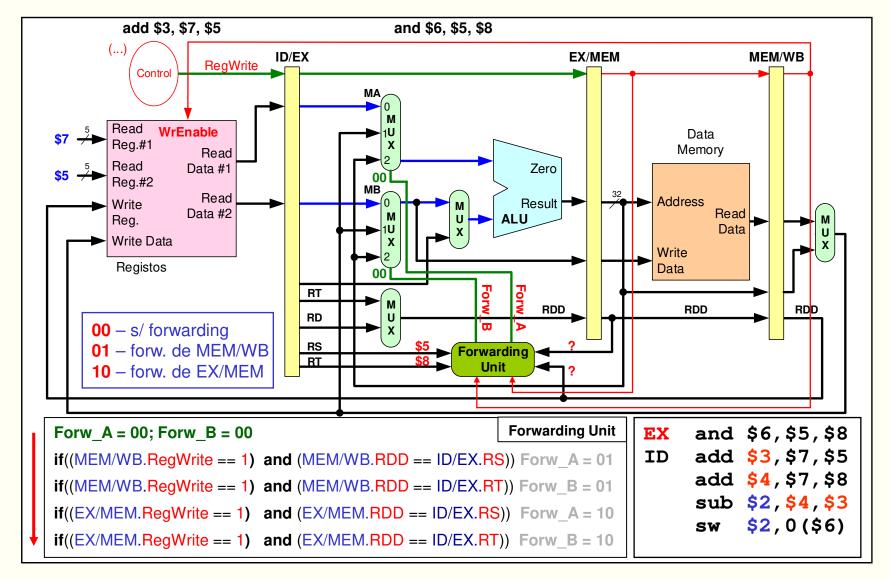
- A instrução "sub \$2,\$4,\$3" apresenta duas situações de hazards de dados:
  - dependência do registo \$4 (add \$4,\$7,\$8)
  - dependência do registo \$3 (add \$3,\$7,\$5)
- A instrução "sw \$2,0 (\$6)" apresenta igualmente uma situação de *hazard* de dados (dependência em \$2, sub \$2,\$4,\$3)

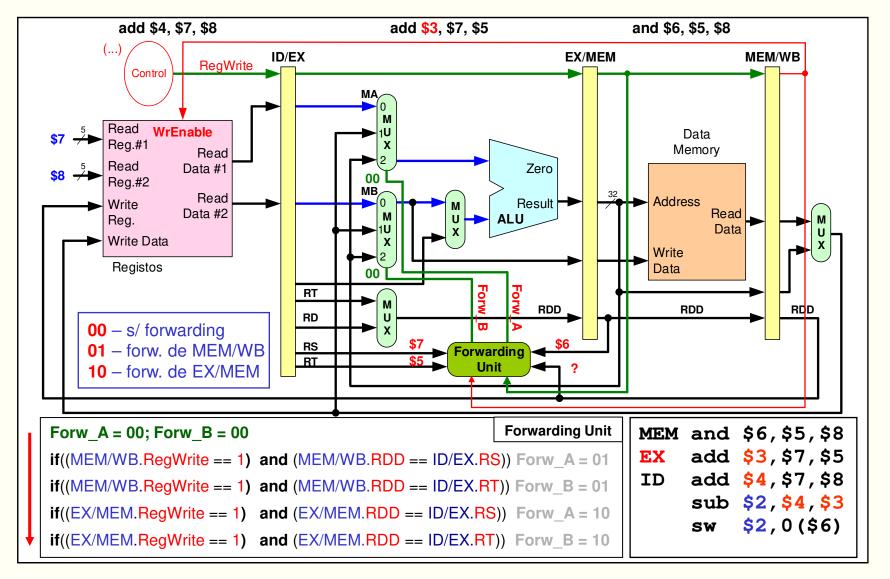


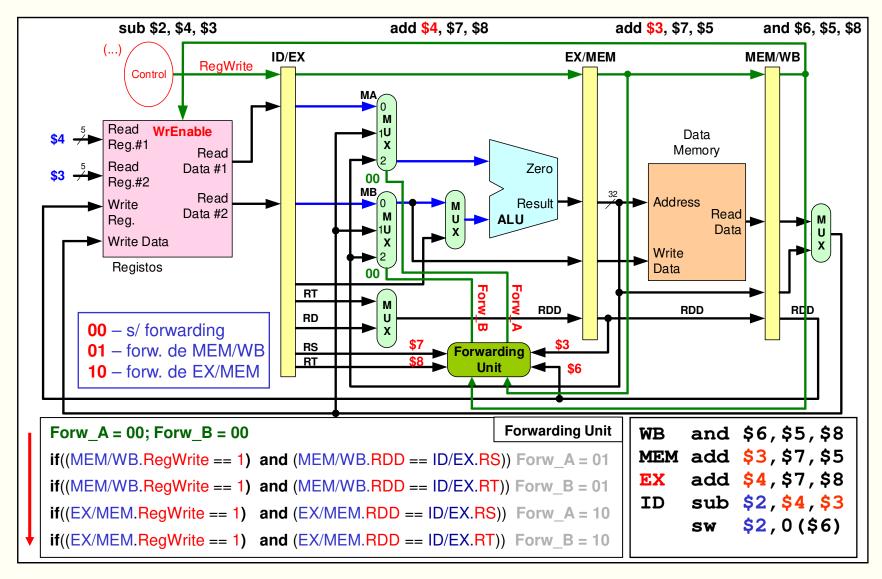
- Dependência de \$3: forwarding de MEM/WB para a 2ª entrada da ALU (registo codificado no campo RT)
- Dependência de \$4: forwarding de EX/MEM para a 1ª entrada da ALU (registo codificado no campo RS)
- Dependência de \$2: forwarding de EX/MEM para o caminho correspondente à 2<sup>a</sup> entrada da ALU (registo codificado no campo RT)

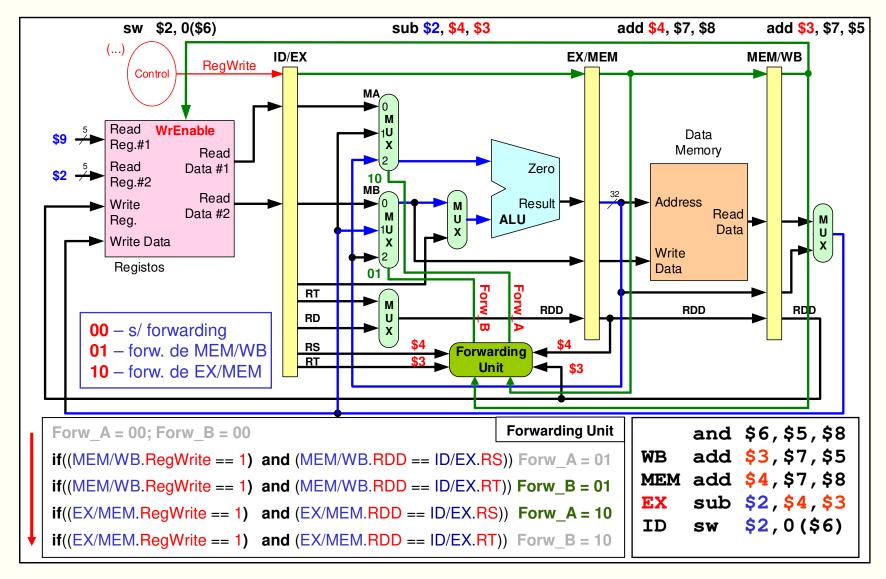


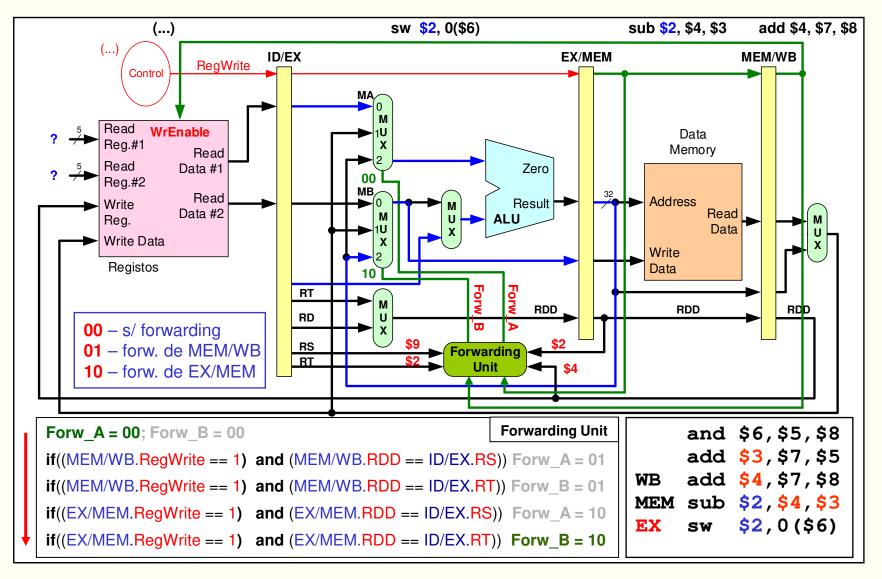








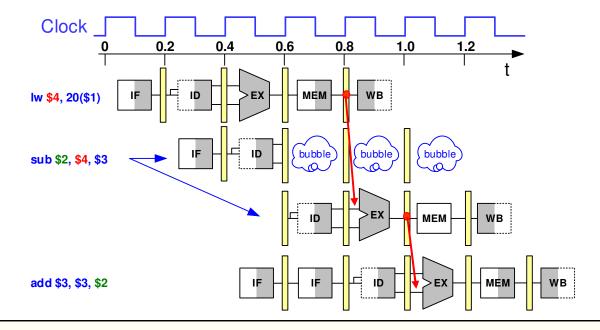




## Dependência que obriga a stalling

• Como já observado anteriormente, uma situação de dependência que obriga a *stalling* é a que resulta de uma instrução aritmética ou lógica executada a seguir e na dependência de uma instrução LW:

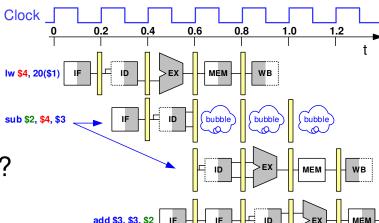
```
lw $4, 20($1) # valor disponível em WB
sub $2, $4, $3 # Stall 1T, Forw. MEM/WB > EX
add $3, $3, $2 # Forw. EX/MEM > EX
```



## Dependência que obriga a stalling

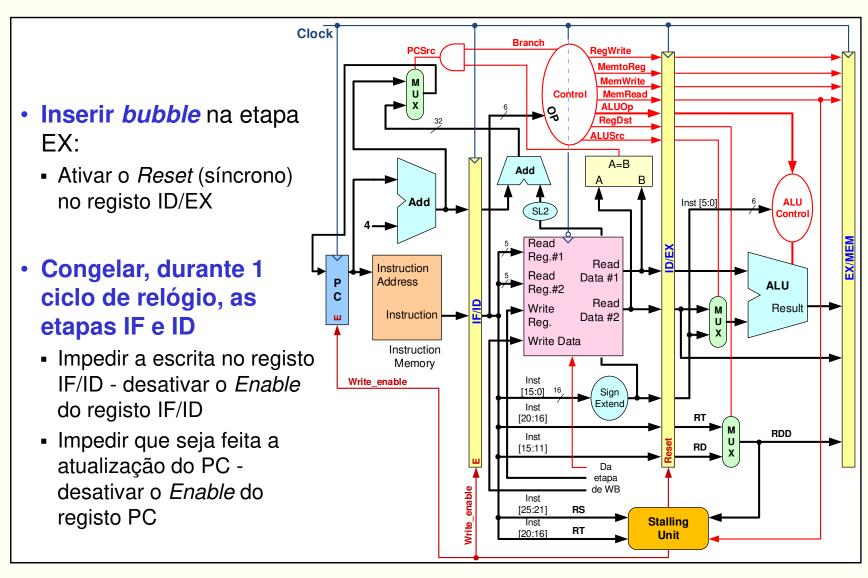
- A situação de stalling tem que ser detetada quando a instrução tipo R está na sua fase ID (e o LW na fase EX). Como detetar?
- De forma simplificada:

(ID/EX.MemRead == 1) and (ID/EX.RDD == RS or ID/EX.RDD == RT)



- Como fazer o stall do pipeline?
  - Inserir bubble na etapa EX: fazer o reset síncrono do registo ID/EX
  - Congelar, durante 1 ciclo de relógio, as etapas IF e ID (i.e. impedir a escrita no registo IF/ID e impedir que seja feita a atualização do PC)

## Unidade de stalling



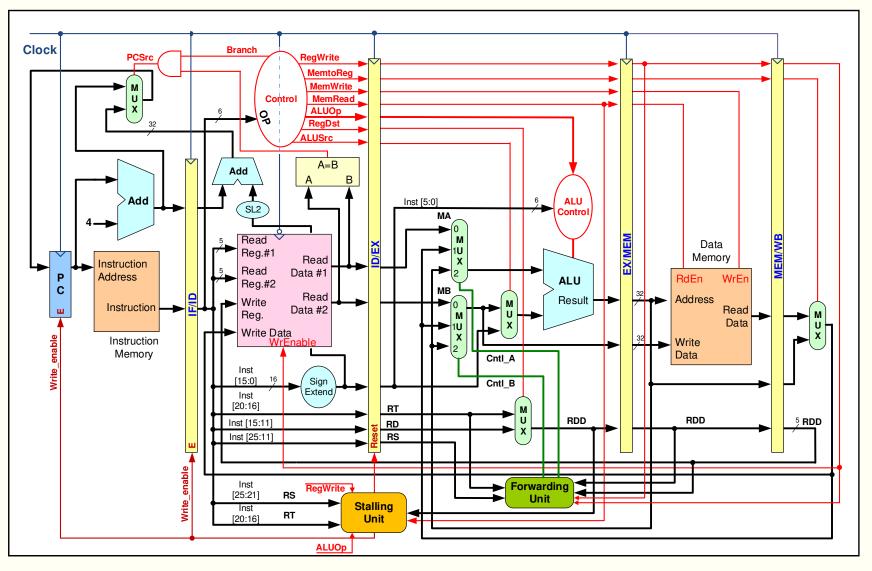
## Unidade de controlo de *stalling* – VHDL

- Unidade de controlo de stalling simplificada, que contempla apenas a situação de dependência entre uma instrução LW e uma instrução tipo R
  - Instrução do tipo R: (ALUOp == "10") and (RegWrite == 1)

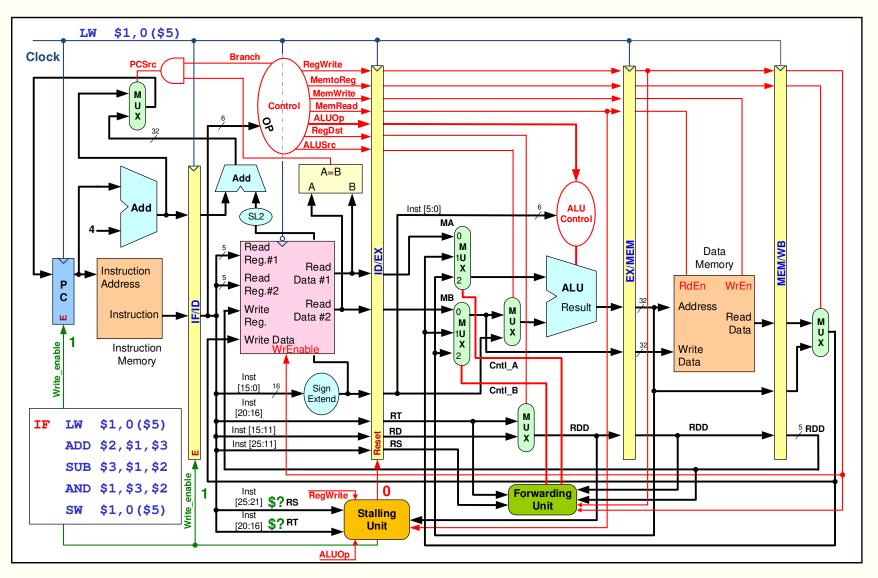
## Unidade de controlo de *stalling* – VHDL

```
architecture Behavioral of StallingUnit is
begin
  process (all)
  begin
    Enable_PC <= '1'; -- Normal flow</pre>
    Enable_IfId <= '1';</pre>
    Reset_IdEx <= '0';</pre>
    if (IdEx_MemRead = '1' and Ex_RDD /= "00000") then
       if (RegWrite = '1' and ALUOp = "10") then
         if (Ex_RDD = RS or Ex_RDD = RT) then
            Enable_PC <= '0'; -- Stall PC</pre>
            Enable_IfId <= '0'; -- Stall IF/ID</pre>
            Reset IdEx <= '1'; -- Bubble in ID/EX
         end if;
       end if;
    end if;
  end process;
end Behavioral;
```

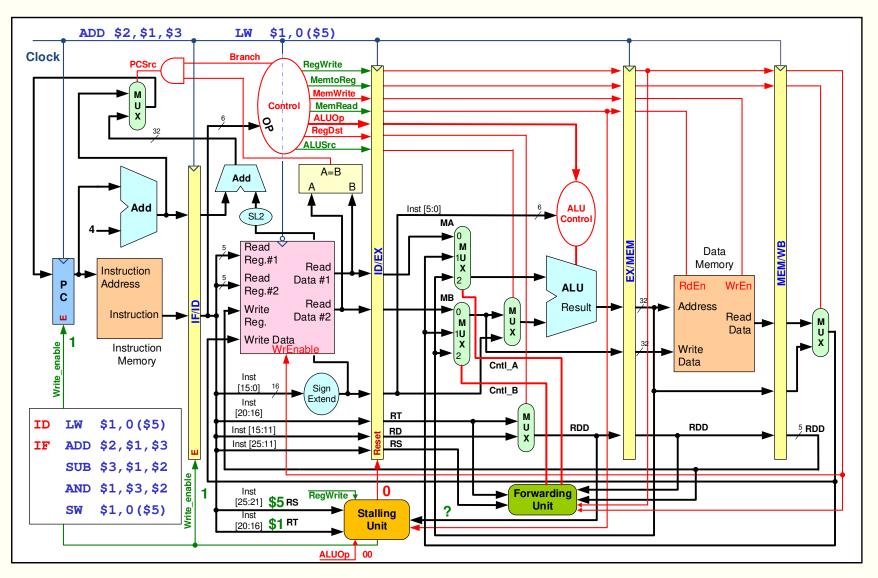
### Datapath pipelining completo (com forwarding para EX, sem j)



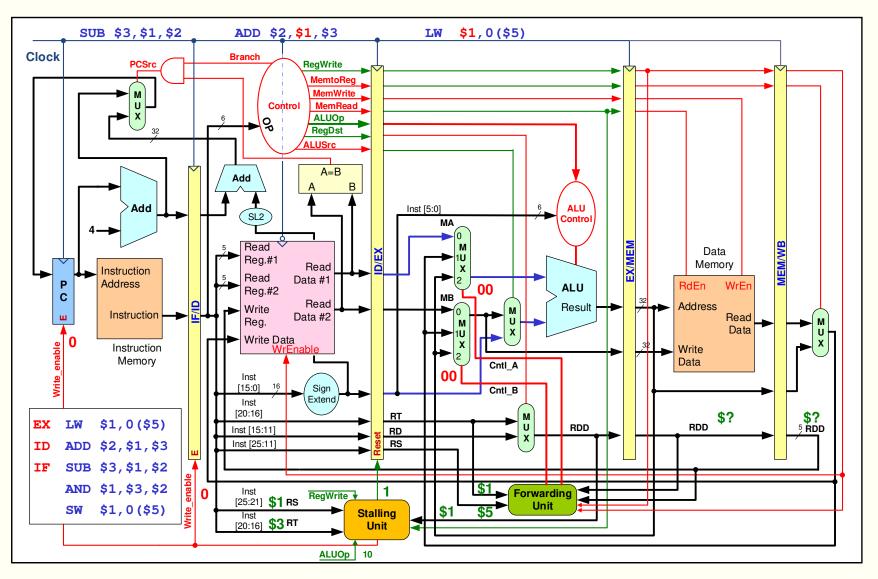
## Datapath pipelining completo – exemplo de execução (1)



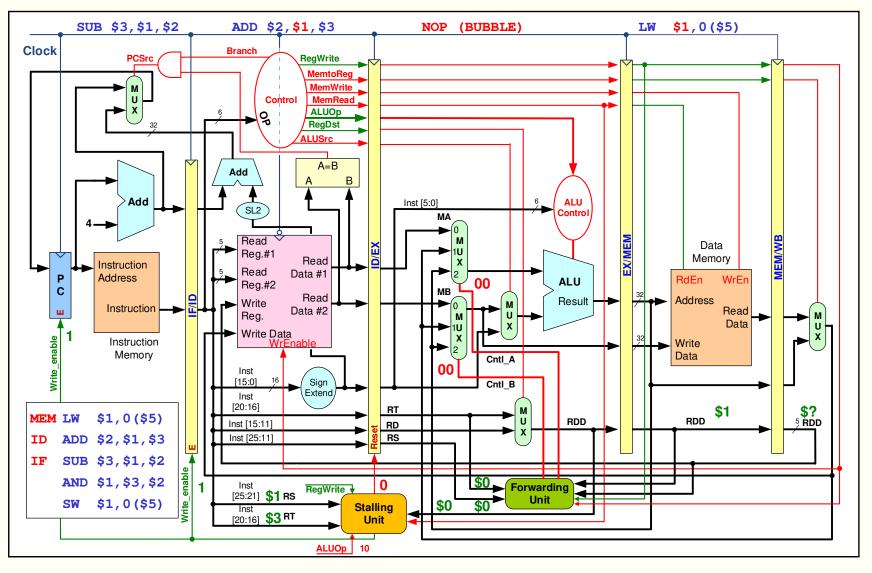
# Exemplo de execução (2) (Normal Flow)



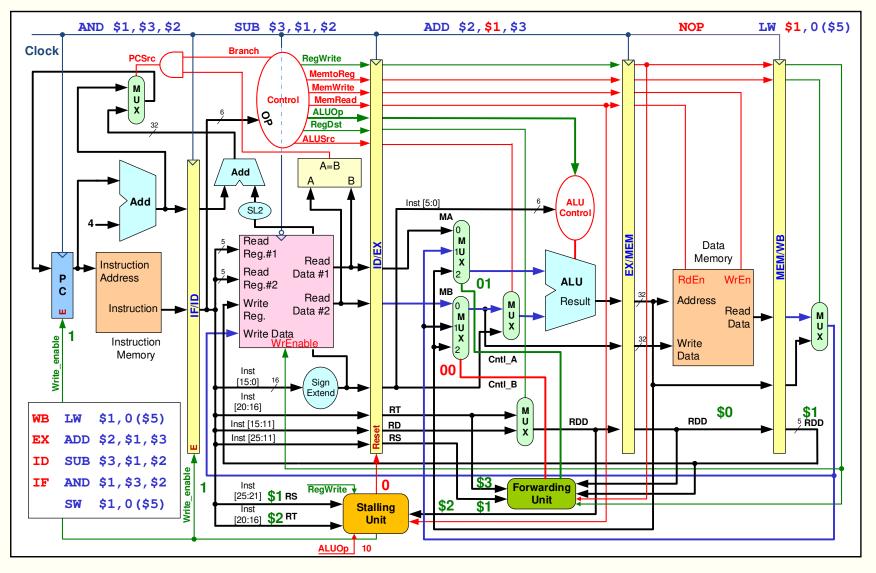
# Exemplo de execução (3) (Normal Flow)



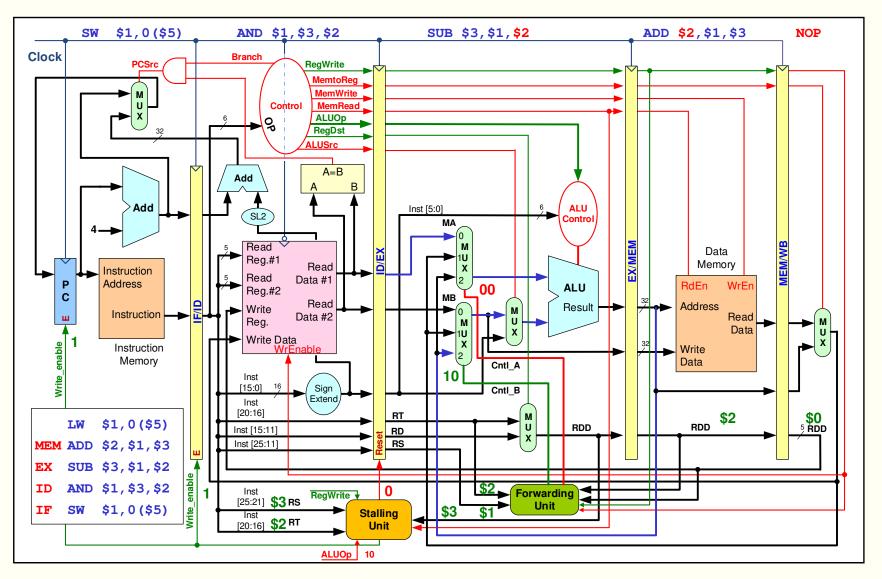
# Exemplo de execução (4) (STALL)



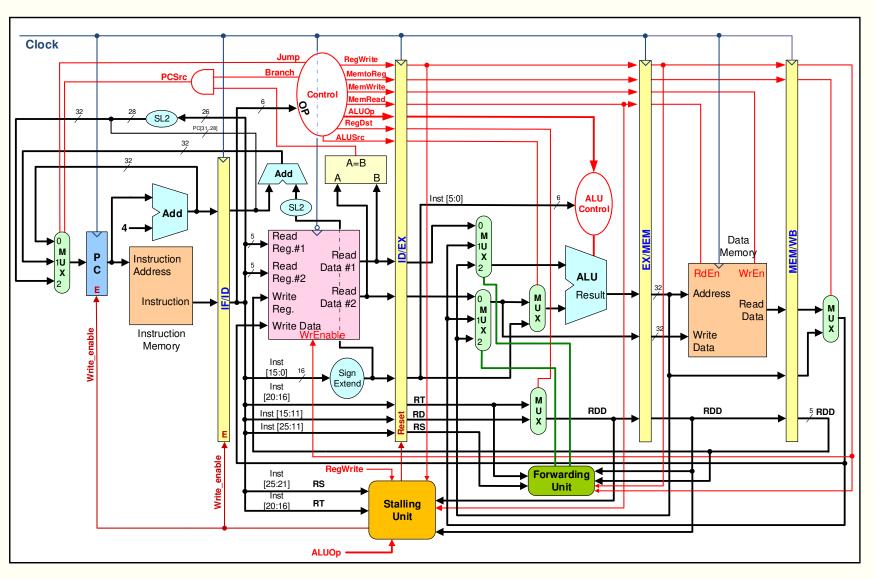
# Exemplo de execução (5) (Fwd: **MEM/WB** > **EX**, **rs**)



# Exemplo de execução (6) (Fwd: **EX/MEM > EX**, **rt**)



# Datapath pipelining completo, com Jump



## Stalling seguido de forwarding para **EX**

• Para além da sequência descrita anteriormente, há outras situações que também são resolvidas com *forwarding* para EX, e que obrigam a *stall* do *pipeline*. Exemplos:

```
lw $1,0($3) #
sw $4,8($1) # Stall 1T, FW MEM/WB > EX (RS)

lw $2,0($3) #
lw $4,8($2) # Stall 1T, FW MEM/WB > EX (RS)

lw $3,0($6) #
addi $4,$3,0x12 # Stall 1T, FW MEM/WB > EX (RS)
```

• Se a arquitetura apenas implementar forwarding para **EX**:

```
lw $4,0($5) #
sw $4,4($4) # Stall 1T, FW MEM/WB > EX (RT)
```

## Forwarding para ID (EX/MEM para ID)

- Os hazards de dados que ocorrem em instruções de branch determinam que a arquitetura deva também implementar forwarding para ID
- Exemplos:

```
(MEM) add $1,$2,$3 #

(EX) sub $2,$4,$6 #

(ID) beq $1,$5,lab # FW EX/MEM > ID (RS)
```

```
(MEM) addi $1,$3,0x25 #

(EX) sub $2,$1,$4, # FW EX/MEM > EX (RS)

(ID) beq $5,$1,lab # FW EX/MEM > ID (RT)
```

## Stalling seguido de forwarding para ID

- Mesmo supondo que a arquitetura implementa *forwarding* para ID (EX/MEM para ID) persistem situações em que há necessidade de fazer *stall* ao *pipeline*.
- Exemplos:

```
add $1,$2,$3 #
beq $1,$5,lab # Stall 1T, FW EX/MEM > ID (RS)
```

```
lw $1,0($5) #
beq $1,$2,lab # Stall 2T
```

## Forwarding para **MEM** (**MEM/WB** para **MEM**)

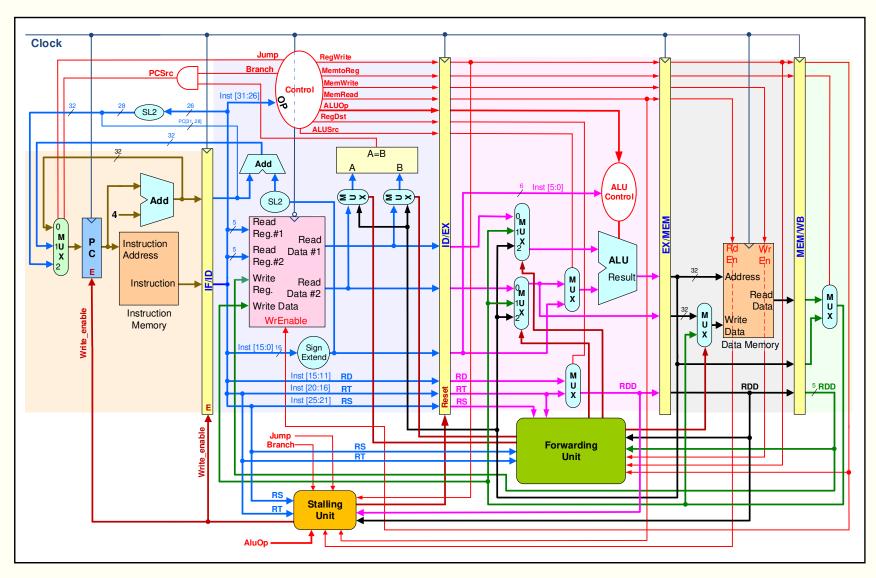
• Uma dependência originada por uma sequência do tipo:

```
lw $1,0($5) #
sw $1,4($4) # Stall 1T, FW MEM/WB > EX (RT)
```

Pode ser resolvida com *stall* durante 1 ciclo de relógio seguido de *forwarding* de **MEM/WB** para **EX** (rt)

- Será mesmo necessário fazer o stall do pipeline?
- A instrução sw só necessita do valor de \$1 no estágio MEM
   (\$4 é necessário em EX), situação em que a instrução LW já
   se encontra em WB
- Esta situação particular pode então ser resolvida com forwarding de MEM/WB para MEM, evitando-se o stall do pipeline

### Datapath pipelining completo, com forwarding para MEM, EX e ID



#### Exercício 1

 Determine o número de ciclos de relógio que o trecho de código seguinte demora a executar num pipeline de 5 fases, desde o instante em que é feito o Instruction Fetch da 1ª instrução, até à conclusão da última:

Num datapath single-cycle o mesmo código demoraria 6 ciclos de relógio a executar. Porque razão é a execução no datapath pipelined mais rápida? Quantos ciclos de relógio demora a execução num datapath multi-cycle?

#### Exercício 2a

 Para o trecho de código seguinte identifique todas as situações de hazard de dados e de controlo que ocorrem na execução num pipeline de 5 fases, com branches resolvidos em ID:

```
main: lw $1,0($0) #
   add $4,$0,$0 #
   lw $2,4($0) #
loop: lw $3,0($1) #
   add $4,$4,$3 # hazard de dados ($3)
   sw $4,36($1) # hazard de dados ($4)
   addi $1,$1,4 #
   slt $5,$1,$2 # hazard de dados ($1)
   bne $5,$0,loop # haz. dados ($5) / haz. controlo
   sw $4,8($0) #
   lw $1,12($0) #
```

#### Exercício 2b

 Apresente o modo de resolução das situações de hazard de dados, admitindo que o pipeline não implementa forwarding:

```
main: lw $1,0($0) #
  add $4,$0,$0 #
  lw $2,4($0) #
loop: lw $3,0($1) #
  add $4,$4,$3 # Stall 2T
  sw $4,36($1) # Stall 2T
  addi $1,$1,4 #
  slt $5,$1,$2 # Stall 2T
  bne $5,$0,loop # Stall 2T
  sw $4,8($0) #
  lw $1,12($0) #
```

### Exercício 2c

 Calcule o número de ciclos de relógio que o programa anterior demora a executar num pipeline de 5 fases, sem forwarding, com branches resolvidos em ID e delayed branch, desde o IF da 1ª instrução até à conclusão da última instrução

```
$1,0($0) # $1=0x10
main: lw
          $4,$0,$0 # $4=0
    add
          $2,4($0) # $2=0x20
    lw
loop: lw $3,0($1) #
    add $4,$4,$3 # Stall 2T
          $4,36($1) # Stall 2T
    SW
    addi $1,$1,4 #
    slt $5,$1,$2 # Stall 2T
          $5,$0,loop # Stall 2T
    bne
          $4,8($0)
    SW
          $1,12($0) #
    lw
```

```
Memória de dados
Addr Value
0x0000000 0x10
0x0000004 0x20
```

- O ciclo é executado 4 vezes: \$1∈[0x10, 0x20[
- Nr de instruções executadas no ciclo: 4 \* 7 = 28
- Nr de instruções executadas fora do ciclo: 3 + 1 = 4
- Nr de *cycle stalls* = 4 \* 8 = 32

$$Nr\_cycles = F + (Nr\_instructions - 1) + Nr\_Cycle\_Stalls$$
  
= 5 + (28 + 4 - 1) + 32 = 68 T

#### Exercício 2d

 Apresente o modo de resolução das situações de hazard de dados, admitindo que o pipeline implementa forwarding para EX e para ID:

```
main: lw $1,0($0) #
   add $4,$0,$0 #
   lw $2,4($0) #
loop: lw $3,0($1) #
   add $4,$4,$3 # Stall 1T, FW MEM/WB > EX (RT)
   sw $4,36($1) # FW EX/MEM > EX (RT)
   addi $1,$1,4 #
   slt $5,$1,$2 # FW EX/MEM > EX (RS)
   bne $5,$0,loop # Stall 1T, FW EX/MEM > ID (RS)
   sw $4,8($0) #
   lw $1,12($0) #
```

#### Exercício 2e

Calcule o número de ciclos de relógio que o programa anterior demora a executar num pipeline de 5 fases, com forwarding para EX e para ID, com branches resolvidos em ID e delayed branch, desde o IF da 1ª instrução até à conclusão da última instrução

```
main: lw $1,0($0)
     add $4,$0,$0
     lw $2,4($0)
loop: lw $3,0($1) #
     add $4,$4,$3 # Stall 1T, FW MEM/WB > EX (RT)
     sw $4,36($1) # FW EX/MEM > EX (RT)
     addi $1,$1,4 #
     slt $5,$1,$2 # FW EX/MEM > EX (RS)
     bne $5,$0,loop # Stall 1T, FW EX/MEM > ID (RS)
     sw $4,8($0) #
     lw $1,12($0)
Nr_cycles = F + (Nr_instructions-1) + Nr_Cycle_Stalls
       = 5 + (28 + 4 - 1) + 8 = 44 T (nr of cycle stalls = 4 * 2 = 8T)
```

#### Exercício 3

Relativamente ao programa da página seguinte a executar num *pipeline* de 5 fases, com *branches* resolvidos em ID e *delayed branch slot*:

- 1. Identifique todas as situações de *hazard* de dados e de controlo
- 2. Apresente o modo de resolução das situações de *hazard* de dados, admitindo que o *pipeline* não implementa *forwarding*
- 3. Calcule o número de ciclos de relógio que o programa demora a executar (na situação da questão anterior), desde o IF da 1ª instrução até à conclusão da última instrução
- Apresente o modo de resolução das situações de hazard de dados, admitindo que o pipeline implementa forwarding para ID, EX e MEM
- 5. Calcule o número de ciclos de relógio que o programa demora a executar (na situação da questão anterior), desde o IF da 1ª instrução até à conclusão da última instrução

Para o mesmo programa, apresente os valores presentes nos registos \$1, \$2, \$3, \$4 e \$5 no final da execução do mesmo.

## Exercício 3 (programa)

```
.data
                      # Segmento de dados: 0x00000000
A1: .word 0x41, 0x43, 0x31, 0x2D, 0x32, 0x30, 0x31, 0x38
A2:
            48
    .space
     .text
     .qlobl main
main: addi $5,$0,0
     addi $4,$0,0x20
     addi $2,$0,7
     add $2,$2,$2
     add $2,$2,$2
     add $2,$2,$4
     lw $3,0($5)
C1:
     sw $3,0($2)
     addi $2,$2,-4
     slt $1,$2,$4
     beq $1,$0,C1
     addi $5,$5,4
     addi $0,$0,0
C2:
```